

TEP / Meta-RL Okuma Dökümü (Set 1-4)

Oct 2, 2026 · @Eren

Bu doküman, rehberdeki 17 kaynağın okunacak ve aranacak kısımlarını `talimatlar.md` rehberine göre tek yerde topluyor. Her bölüm rehberdeki görevle başlıyor, ardından döküm geliyor. Bölüm sırası rehberin üç başlığını izliyor: 1-6 TEP kaynakları, 7-11 timestep ve pencere, 12-17 latent boyutu. 18. bölüm hepsinden çıkan proje kararlarını, 19. bölüm okuma durumunu topluyor.

"(doğrula)" işaretli değerler PDF metninden net okunamadı, kodlamadan önce PDF'te gözle kontrol edilmeli.

1. Downs & Vogel (1993): TEP problem tanımı

Görev (rehber). Oku: proses açıklaması; XMEAS, XMV, IDV tabloları; shutdown limitleri; base-case değerleri. Atla: ekonomik maliyet fonksiyonu (ödül aşamasında dönülecek). Ara: hangi ölçüm ne sıklıkla örnekleniyor, analizör gecikmeleri.

Ara'nın cevabı. XMEAS 1-22 sürekli ölçümlerdir. Analizörler ise ayırık ve gecikmelidir. XMEAS 23-36 her 6 dakikada bir gelir ve geldiğinde 6 dakika eskidir. Ürün analizörü (XMEAS 37-41) her 15 dakikada bir gelir, 15 dakika eskidir ve bir sonraki güncellemeye kadar 30 dakika eskiye ulaşır.

Kaynak	XMEAS	Yeni değer aralığı	Geldiğindeki yaşı	Güncellemeden hemen önceki yaşı	3 dk örneklemede
Sürekli ölçümler	1-22	her adım	0	0	her örnekte değişir
Reaktör beslemesi analizörü (stream 6)	23-28	0.1 h (6 dk)	6 dk	12 dk	2 örnekte bir değişir
Purge analizörü (stream 9)	29-36	0.1 h (6 dk)	6 dk	12 dk	2 örnekte bir değişir
Ürün analizörü (stream 11)	37-41	0.25 h (15 dk)	15 dk	30 dk	5 örnekte bir değişir

Sürekli ölçümlere ölçüm tipine uygun Gaussian gürültü eklenir. TIME = 0 anında gürültü yoktur.

Proses

- 8 bileşen: gaz reaktanlar A, C, D, E; inert B; yan ürün F; sıvı ürünler G ve H.
- 4 tersinmez, ekzotermik reaksiyon:

- $A + C + D \rightarrow G$ (ürün 1)
- $A + C + E \rightarrow H$ (ürün 2)
- $A + E \rightarrow F$ (yan ürün)
- $3D \rightarrow 2F$ (yan ürün)
- Hızlar Arrhenius ile sıcaklığa bağlı. G reaksiyonunun aktivasyon enerjisi daha yüksek, bu yüzden sıcaklığa daha duyarlı. Reaktan konsantrasyonlarına göre yaklaşık birinci dereceden.
- 5 ünite: reaktör, ürün kondenseri, buhar-sıvı ayırıcı, geri dönüşüm kompresörü, stripper.
- Akış: gaz beslemeler reaktöre girer; katalizör sıvı fazda çözünmüş ve uçucu değil. Ürünler reaktörden buhar olarak çıkar, kondenserde soğur, ayırıcıya gider. Yoğuşmayanlar santrifüj kompresörle reaktör beslemesine döner. Yoğuşanlar stripper'a gider ve stream 4 ile sıyrılır; G ve H stripper tabanından çıkar. B ve F esas olarak ayırıcıdan purge ile atılır.
- Reaktörde iç soğutma demeti var. Ajitasyon hızı yalnızca ısı transfer katsayısını etkiler.
- Ricker (1996) ve Reinartz (2021) notu: proses açık çevrimde kararsız; kontrolcü olmadan hızla shutdown'a gider.

Çalışma modları

Mod	G/H kütle oranı	Üretim (stream 11)
1 (base case)	50/50	7038 kg/h G + 7038 kg/h H
2	10/90	1408 kg/h G + 12,669 kg/h H
3	90/10	10,000 kg/h G + 1111 kg/h H
4	50/50	maksimum
5	10/90	maksimum
6	90/10	maksimum

XMV: 12 manipüle değişken (Tablo 3)

Değerler 0–100 olarak verilir, simülatör bunları tablodaki fiziksel aralığa ölçekler.

XMV	Değişken	Base (%)	0 → 100 karşılığı
1	D besleme debisi (stream 2)	63.053	0–5811 kg/h
2	E besleme debisi (stream 3)	53.980	0–8354 kg/h

XMV	Değişken	Base (%)	0 → 100 karşılığı
3	A besleme debisi (stream 1)	24.644	0–1.017 kscmh
4	A + C besleme debisi (stream 4)	61.302	0–15.25 kscmh
5	Kompresör geri dönüş vanası	22.210	0–100 %
6	Purge vanası (stream 9)	40.064	0–100 %
7	Ayırıcı sıvı debisi (stream 10)	38.100	0–65.71 m ³ /h
8	Stripper sıvı ürün debisi (stream 11)	46.534	0–49.10 m ³ /h
9	Stripper buhar vanası	47.446	0–100 %
10	Reaktör soğutma suyu debisi	41.106	0–227.1 m ³ /h
11	Kondenser soğutma suyu debisi	18.114	0–272.6 m ³ /h
12	Ajitatör hızı	50.000	150–250 rpm

- Debi birimiyle verilen XMV'lerde (kscmh, kg/h, m³/h) akış basınçtan bağımsızdır. Vana konumu olanlarda (5, 6, 9) akış basınca bağlıdır; sabit debi isteniyorsa ayrı bir debi kontrolcüsü gerekir.
- 0–100 dışı değer girilebilir, ama etkisi 0 veya 100'de kırılır. XMV değişkeninin kendisi değişmez.

XMEAS 1–22: sürekli ölçümler (Tablo 4)

XMEAS	Ölçüm	Base	Birim
1	A besleme (stream 1)	0.25052	kscmh
2	D besleme (stream 2)	3664.0	kg/h
3	E besleme (stream 3)	4509.3	kg/h
4	A + C besleme (stream 4)	9.3477	kscmh
5	Geri dönüş debisi (stream 8)	26.902	kscmh
6	Reaktör besleme debisi (stream 6)	42.339	kscmh
7	Reaktör basıncı	2705.0	kPa gauge
8	Reaktör seviyesi	75.000	%
9	Reaktör sıcaklığı	120.40	°C

XMEAS	Ölçüm	Base	Birim
10	Purge debisi (stream 9)	0.33712	kscmh
11	Ayırıcı sıcaklığı	80.109	°C
12	Ayırıcı seviyesi	50.000	%
13	Ayırıcı basıncı	2633.7	kPa gauge
14	Ayırıcı alt akışı (stream 10)	25.160	m³/h
15	Stripper seviyesi	50.000	%
16	Stripper basıncı	3102.2	kPa gauge
17	Stripper alt akışı (stream 11)	22.949	m³/h
18	Stripper sıcaklığı	65.731	°C
19	Stripper buhar debisi	230.31	kg/h
20	Kompresör işi	341.43	kW
21	Reaktör soğutma suyu çıkış sıcaklığı	94.599	°C
22	Ayırıcı soğutma suyu çıkış sıcaklığı	77.297	°C

XMEAS 23-41: analizörler, mol % (Tablo 5)

XMEAS	Akım	Bileşen	Base (mol %)
23	Reaktör beslemesi (stream 6)	A	32.188
24	Reaktör beslemesi (stream 6)	B	8.8933
25	Reaktör beslemesi (stream 6)	C	26.383
26	Reaktör beslemesi (stream 6)	D	6.8820
27	Reaktör beslemesi (stream 6)	E	18.776
28	Reaktör beslemesi (stream 6)	F	1.6567
29	Purge (stream 9)	A	32.958
30	Purge (stream 9)	B	13.823
31	Purge (stream 9)	C	23.978
32	Purge (stream 9)	D	1.2565

XMEAS	Akım	Bileşen	Base (mol %)
33	Purge (stream 9)	E	18.579
34	Purge (stream 9)	F	2.2633
35	Purge (stream 9)	G	4.8436
36	Purge (stream 9)	H	2.2986
37	Ürün (stream 11)	D	0.01787
38	Ürün (stream 11)	E	0.83570
39	Ürün (stream 11)	F	0.09858
40	Ürün (stream 11)	G	53.724
41	Ürün (stream 11)	H	43.828

İşletme kısıtları (Tablo 6)

Değişken	Normal alt	Normal üst	Shutdown alt	Shutdown üst
Reaktör basıncı	yok	2895 kPa	yok	3000 kPa
Reaktör seviyesi	%50 (11.8 m ³)	%100 (21.3 m ³)	2.0 m ³	24.0 m ³
Reaktör sıcaklığı	yok	150 °C	yok	175 °C
Ayırıcı seviyesi	%30 (3.3 m ³)	%100 (9.0 m ³)	1.0 m ³	12.0 m ³
Stripper taban seviyesi	%30 (3.5 m ³)	%100 (6.6 m ³)	1.0 m ³	8.0 m ³

Shutdown limiti aşıldığında TEFUNC tüm türevleri sıfırlar ve proses durur. Yeniden başlatmak için TEINIT çağrılmalı; bu da base-case'e döner.

IDV: 20 bozucu (Tablo 8)

IDV	Bozucu	Tip
1	A/C besleme oranı, B kompozisyonu sabit (stream 4)	Basamak
2	B kompozisyonu, A/C oranı sabit (stream 4)	Basamak
3	D besleme sıcaklığı (stream 2)	Basamak
4	Reaktör soğutma suyu giriş sıcaklığı	Basamak

IDV	Bozucu	Tip
5	Kondenser soğutma suyu giriş sıcaklığı	Basamak
6	A besleme kaybı (stream 1)	Basamak
7	C header basınç kaybı, düşük erişilebilirlik (stream 4)	Basamak
8	A, B, C besleme kompozisyonu (stream 4)	Rastgele değişim
9	D besleme sıcaklığı (stream 2)	Rastgele değişim
10	C besleme sıcaklığı (stream 4)	Rastgele değişim
11	Reaktör soğutma suyu giriş sıcaklığı	Rastgele değişim
12	Kondenser soğutma suyu giriş sıcaklığı	Rastgele değişim
13	Reaksiyon kinetiği	Yavaş sürüklenme
14	Reaktör soğutma suyu vanası	Yapışma
15	Kondenser soğutma suyu vanası	Yapışma
16–20	Bilinmiyor	Bilinmiyor

- IDV bir 0/1 bayrağıdır (INTEGER*4). Genlik parametresi yoktur; README'deki "severity ayarlanamaz" sorununun kökü budur.
- Bozucular her an ayrı ayrı veya birlikte açılıp kapatılabilir, 6 modun hepsinde geçerlidir. Bayrak 0'a dönünce ilgili değişkenler base değerine döner.
- IDV 14–20 tek başına değil, başka bir bozucu veya setpoint değişikliğiyle birlikte kullanılmalı.
- Tam etki için 24–48 saatlik simülasyon önerilir.

Base-case akım ve ünite değerleri (Tablo 1)

Stream	Akım	Molar debi (kmol/h)	Kütle debisi (kg/h)	Sıcaklık (°C)
1	A beslemesi	11.2	22.4	45.0
2	D beslemesi	114.5	3664.0	45.0
3	E beslemesi	98.0	4509.3	45.0
4	C beslemesi (%48.5 A, %0.5 B, %51 C)	417.5	6419.4	45.0

Stream	Akım	Molar debi (kmol/h)	Kütle debisi (kg/h)	Sıcaklık (°C)
5	Stripper tepe	465.7	8979.6	65.7
6	Reaktör beslemesi	1890.8	48,015.4	86.1
7	Reaktör ürünü	1476.0	48,015.4	120.4
8	Geri dönüş	1201.5	30,840.0	102.9
9	Purge	15.1	386.5	80.1
10	Ayırıcı sıvısı	259.5	16,788.9	80.1
11	Ürün	211.3	14,228.6	65.7

- Reaktör: 120.4 °C, 2705.0 kPa, ısı yükü –6468.7 kW, sıvı hacmi 16.55 m³.
- Ayırıcı: 80.1 °C, 2633.7 kPa, sıvı hacmi 4.88 m³. Kondenser ısı yükü –2140.6 kW.
- Stripper: 65.7 °C, 3102.2 kPa, ısı yükü 1430.0 kW, sıvı hacmi 4.43 m³.
- Yardımcılar: reaktör soğutma suyu 93.37 m³/h, kondenser soğutma suyu 49.37 m³/h, stripper buharı 230.31 kg/h.

Kontrol hedefleri ve değişkenlik sınırları

- Ürün debisi (stream 11): 8–16 h⁻¹ frekans bandında $\pm 5\%$ 'i aşan değişim zararlı.
- Ürün kompozisyonu: 6–10 h⁻¹ bandında ± 5 mol% G'yi aşan değişim zararlı.
- Beslemeler: stream 4 için 12–80 h⁻¹ bandındaki değişkenlik öncelikli olarak azaltılmalı; stream 1 ve 2 için 8–16 h⁻¹. E beslemesi (stream 3) kritik değil, ama manipüle değişkenlerde yüksek frekanslı titreşim istenmez.
- Önerilen karşılaştırma seti (Mod 1): dört setpoint değişikliği (üretim –%15, 14,228 → 12,094 kg/h; ürün karışımı 50G/50H → 40G/60H; reaktör basıncı 2705 → 2645 kPa; purge B 13.82 → 15.82 mol%) ve dört yük bozucusu (IDV 1, IDV 4, IDV 8, IDV 12 ile IDV 15 birlikte). İzlenecekler: A, D, E, C besleme debileri, ürün debisi ve kompozisyonu, reaktör basıncı.

Model notları

- 50 state. TEFUNC türevleri ve ölçümleri hesaplar, TEINIT base-case'i başlatır; entegratörü kullanıcı sağlar.
- İdeal gaz, Raoult yasası + Antoine denklemi; kaplar tam karışmış, dağılmış parametre yok.
- En hızlı mod: özdeğer 1968 h⁻¹, zaman sabiti yaklaşık 1.8 s. Örnek programda Euler entegratörü 1 s adımla kararlı.

- Transmitter gecikmesi gibi hızlı dinamikler modelde yok. Model, başlatma ve durdurma prosedürleri için tasarlanmamış.
- Kaydedilmiş bir durumdan devam etmek için YY ve XMV yüklenir, TIME = 0 yapıp TEFUNC çağrılır; örneklenen analizör ölçümleri böylece doğru başlatılır.

Atlanan: maliyet fonksiyonu

Tablo 9'da: bileşen fiyatları, purge ve ürünlerdeki hammadde kayıpları, kompresör işi ve buhar maliyeti. Base-case toplamı 170.6 \$/h. Ödül fonksiyonu aşamasında bu tabloya dönülecek.

2. Ricker (1996): dağıtık (decentralized) kontrol

Görev (rehber). Oku: kontrol yapısı (hangi XMV hangi XMEAS'ı kontrol ediyor), döngü eşleştirme tablosu, override mantığı. Atla: tasarım gerekçelerinin uzun tartışması. Ara: kontrolcü parametre tablosu; PI baseline buna göre kodlanacak.

Ara'nın cevabı. Parametreler Tablo 2'de: 19 döngü, her biri için kontrol edilen ve manipüle edilen değişken, kazanç ve dakika cinsinden integral süresi. Tam hali aşağıda.

Yapının özeti

- Üretim hızı tek bir "üretim indeksi" F_p ile yönetilir. $F_p = 100$, base-case'teki stream 11 debisine (23.0 m³/h) karşılık gelir.
- Stream 1, 2, 3, 4, 9, 10 ve 11 oran kontrolündedir: her akımın debi setpoint'i $r_i \cdot F_p$. F_p değişince bütün beslemeler ve çıkışlar orantılı değişir.
- Envanter: stripper seviyesi → stream 11 oranı; ayırıcı seviyesi → stream 10 oranı; reaktör seviyesi → ayırıcı sıcaklık setpoint'i (kondenser suyu ile kaskad); reaktör basıncı → purge oranı.
- Ürün %G → D ve E besleme oranları (feedforward tablo + yavaş feedback).
- A ve C envanteri → r_1 ve r_4 (reaktör beslemesi analizöründen).
- Reaktör sıcaklığı → reaktör soğutma suyu vanası.
- Sabit tutulanlar: ajitatör %100 (soğutma kapasitesi maksimum); buhar vanası sabit (optimumda genelde tam kapalı); geri dönüş vanası setpoint'te (genelde kapalı), yalnız override devreye girince oynar.

Döngü ve PI parametre tablosu (Tablo 2)

İntegral süresi dakika cinsinden. Döngü 1–7 oran + debi kontrolüdür; tablodaki sabitler debi kontrolcüsüne aittir. XMV numaraları Downs & Vogel Tablo 3'e göredir.

Döngü	Kontrol edilen	Manipüle edilen	Kazanç Kc	Ti (dk)
1	A besleme debisi (stream 1)	XMV 3	0.01	0.001
2	D besleme debisi (stream 2)	XMV 1	1.6×10^{-6}	0.001
3	E besleme debisi (stream 3)	XMV 2	1.8×10^{-6}	0.001
4	C besleme debisi (stream 4)	XMV 4	0.003	0.001
5	Purge debisi (stream 9)	XMV 6	0.01	0.001
6	Ayırıcı sıvı debisi (stream 10)	XMV 7	4.0×10^{-4}	0.001
7	Stripper sıvı debisi (stream 11)	XMV 8	4.0×10^{-4}	0.001
8	Üretim hızı	Fp	2.0	400
9	Stripper sıvı seviyesi	Döngü 7'nin oranı	-2.0×10^{-4}	200
10	Ayırıcı sıvı seviyesi	Döngü 6'nın oranı	-1.0×10^{-3} (doğrula)	200
11	Reaktör sıvı seviyesi	Döngü 17'nin setpoint'i	0.8	60
12	Reaktör basıncı	Döngü 5'in oranı	-1.0×10^{-4}	20
13	Ürün mol% G (stream 11)	E_adj (Denklem 5-6)	-0.4	100
14	y_A (Denklem 7)	Döngü 1'in oranı r1	2.0×10^{-4}	60
15	y_AC (Denklem 8)	r1 + r4 toplamı	3.0×10^{-4}	120
16	Reaktör sıcaklığı	Reaktör soğutma vanası (XMV 10)	-8.0	7.5
17	Ayırıcı sıcaklığı	Kondenser soğutma vanası (XMV 11)	-4.0	15
18	Maks. reaktör basıncı (override)	Üretim indeksi Fp	2.0×10^{-6} (doğrula)	0.001

Döngü	Kontrol edilen	Manipüle edilen	Kazanç Kc	Ti (dk)
19	Reaktör seviye override	Geri dönüş vanası (XMV 5)	1.0×10^{-6} (doğrula)	1.0×10^{-5} (doğrula)

PDF metninde üslerin eksi işaretleri çoğu satırda kaybolmuş. Negatif üs kabul edildi, çünkü pozitif üs fiziksel olarak anlamsız büyüklükte kazanç verir. Döngü 10'un üssü ile döngü 18 ve 19'un değerleri metinde okunamıyor; PDF'te veya Bathelt'in Multiloop kodunda kontrol edilmeli.

Oran kontrolü ve üretim hızı (döngü 1-8)

$$y_i^{\{sp\}}(t) = r_i(t) \setminus F_p(t)$$

- Fp'deki basamak değişiklikleri otomatik rampaya çevrilir: 24 saatte en fazla $\pm\%30$.
- Doymayı yakalamak için her beslemenin maksimum debisi doğrusal ekstrapolasyonla tahmin edilir. Bu yalnız $u_i > 50$ iken yapılır, aksi halde önceki tahmin tutulur. y_i ölçülen debi, u_i vana konumu (%).

$$y_i^{\{max\}}(t) = 100 \setminus \frac{y_i(t)}{u_i(t)}, \quad \text{\\quad} F_i^{\{max\}}(t) = \frac{y_i^{\{max\}}(t)}{r_i(t)}, \quad \text{\\quad} F_p(t) = \min_i F_i^{\{max\}}(t)$$

- Son eşitlik yalnızca bir setpoint tahmini maksimumu aşınca uygulanır. Böylece beslemeler oranlar bozulmadan kısıtla itilir; maksimum üretim modları bu yolla çalışır.
- Döngü 8 (Fp trim) stream 11'deki kalıcı sapmayı siler. Düzeltme ± 10 birimle sınırlı; üretim kısıttayken windup'a karşı kapatılır.

Envanter döngüleri (9-12)

- Döngü 9: stripper seviyesi, stream 11 oranıyla.
- Döngü 10: ayırıcı seviyesi, stream 10 oranıyla. Setpoint'i sabit değil, stripper seviyesinin anlık değeri; iki seviye birlikte hareket edip ürün debisindeki dalgalanmayı azaltır.
- Döngü 11: reaktör seviyesi, ayırıcı sıcaklık setpoint'ini (döngü 17) ayarlar. Ayırıcı soğuyunca daha az G ve H geri döner, reaktörden buharlaşma artar ve seviye düşer.
- Döngü 12: reaktör basıncı, purge oranıyla. Sabit reaktör sıcaklığıyla birlikte, B ve F gibi birikebilecek bileşenleri de dolaylı olarak düzenler.
- Seviye döngüleri bilinçli olarak gevşek ayarlı; ayırıcı ve stripper tampon tank gibi davranır.

Ürün kompozisyonu (döngü 13)

$$r_2(t) = r_{2FF}(t) - \frac{32 \cdot E_{adj}(t)}{F_p(t)}, \quad r_3(t) = r_{3FF}(t) + \frac{46 \cdot E_{adj}(t)}{F_p(t)}$$

- E_{adj} , E'nin molar beslemesine yapılan düzeltmedir; 32 ve 46, D ve E'nin mol kütleleri. %G yüksekse D azalır, E aynı molar miktarda artar ve toplam üretim korunur.
- İşaret notu: metin "D azalır, E artar" diyor; PDF denklem metninde r_3 için eksi görünüyor (doğrula).
- Döngü 13, 0.25 h örnekleme periyotlu ayırık PI (ürün analizörüyle senkron). Feedback bilerek yavaş ayarlı, işin çoğunu feedforward yapar.
- %G setpoint'indeki basamaklar da rampaya çevrilir: 24 saatte en fazla ± 50 G.
- Feedforward oranları, %G hedefine göre aşağıdaki tablodan doğrusal interpolasyonla alınır (Tablo 3):

Setpoint mol% G	r_{2FF}	r_{3FF}
11.7	7.44	81.44
53.7	36.58	44.34
90.1	66.17	8.94

- Ürün kayıpları (üründeki D ve E) için ayrı döngü yok; buhar vanası sabit tutulur. Stripper buharının %G üzerinde fark edilir bir etkisi yok.

A ve C envanteri (döngü 14-15)

$$y_A = 100 \cdot \frac{X_{MEAS}(23)}{X_{MEAS}(23) + X_{MEAS}(25)}, \quad y_{AC} = X_{MEAS}(23) + X_{MEAS}(25)$$

$$r_1(t) = r_1(t - \Delta t) + \Delta r_1(t), \quad r_4(t) = r_4(t - \Delta t) + \Delta r_{14}(t) - \Delta r_1(t)$$

- Δr_1 döngü 14'ün, Δr_{14} döngü 15'in çıkışı. İkisi de hız-formunda ayırık PI, 0.1 h periyotlu (reaktör beslemesi analizörüyle senkron); önce döngü 14 çalışır.
- r_4 'ün alt sınırı 0.084; A beslemesi kaybı gibi büyük bozucularda aşmayı önler.
- Amaç A ve C'yi fazlada tutmak; böylece D reaksiyon 1'i, E reaksiyon 2'yi sınırlar ve D ile E kendiliğinden dengelenir.

Sıcaklık döngüleri (16-17)

- Döngü 16: reaktör sıcaklığı, reaktör soğutma vanasıyla. Çoğu durumda setpoint'in 0.1 °C içinde, hiçbir zaman 1 °C'den fazla sapmamış.
- Döngü 17: ayırıcı sıcaklığı, kondenser soğutma vanasıyla. Döngü 11'in iç (slave) döngüsü; kondenser suyu sıcaklık bozucularını reaktör seviyesine ulaşmadan söndürür.

Override mantığı (döngü 18-19)

- **Döngü 18, yüksek basınç.** Reaktör basıncı 2950 kPa'yı aşınca devreye girer. PI, setpoint 2950 kPa, çıkışı $Fp, OR \leq 0$ ve Fp' ye eklenir. Bütün beslemeler orantılı azalır ve basınç düşer. Purge vanası doyduğunda basınç kontrolü bu yolla korunur; A beslemesi kaybında üretim yalnız ~%15 düşerek proses ayakta kalmış.
- **Döngü 19, kondenser vanası doyması.** Geri dönüş vanası iki override ile ayarlanır:
 - Yüksek override: kondenser vanası %95'e yaklaşırsa ($çıkış \leq 0$) geri dönüş vanası kapanır, geri dönüş debisi artar ve reaktör seviyesi düşer.
 - Düşük override: kondenser vanası %5'e yaklaşırsa ($çıkış \geq 0$) vana açılır.
 - $XMV\ 5 = u5, sp + u5, Hi + u5, Lo$. Normalde iki override sinyali de sıfırdır.
- **Besleme doyması:** yukarıdaki maksimum debi mantığı üretim hedefini otomatik düşürür; ayrı ve bağımsız bir mekanizmadır.
- **Eklenmeyenler:** reaktör sıcaklığı ve seviyesi için override gerekmedi; reaktör soğutma vanası hiçbir testte doymadı. Ayırıcı ve stripper seviyeleri aşırı durumlarda alarm limitini aşabilir, değişim yavaş olduğu için operatöre bırakılmış.

Önerilen setpoint'ler ve serbest değişkenler

Değişken	Öneri	Not
Reaktör basıncı	2850 kPa	Normalde ± 40 kPa içinde kalır
Reaktör seviyesi	%55	Tipik sapma $\pm \%5$
Reaktör sıcaklığı	120-130 °C	Nominal üretimde optimum Mod 3 / 1 / 2 için 122 / 123 / 124 °C; ± 2 °C sapma maliyeti %3'ten az artırıyor
y_A	$63 \pm \%1$	Mod 1-3 optimumu; $\pm \%5$ sapma maliyeti %4'ten az artırıyor
y_AC	%48 (Mod 3) - %54 (Mod 2)	%5 fazlası maliyeti %11'e kadar artırıyor

Değişken	Öneri	Not
Geri dönüş vanası	Genelde kapalı	Mod 1'de %30 açık olursa maliyet ~%5 artıyor
Buhar vanası	Sabit, genelde tam kapalı	%G'ye etkisi yok
Ajitatör	%100	

Bathelt ve Reinartz'ın kullandığı Multiloop modelindeki setpoint'ler bunlardan farklı (2800 kPa, seviye %65); bkz. bölüm 4.

3. Rieth et al. (2017): ek TEP simülasyon verisi

Görev (rehber). Oku: veri seti açıklaması (kaç simülasyon, kaç örnek, arıza başlangıç anı, örnekleme periyodu). Kısa bir doküman olduğu için tamamı okunabilir.

Kaynak notu. Gönderilen rieth.pdf iki seferde de Reinartz et al. (2021) çıktı. Veri setinin Harvard Dataverse sayfası bu ortamdan açılmadı. Aşağıdaki bilgiler, veri setini kullanan ikincil kaynaklardan ve bu dokümandaki Lomov ve Reinartz bölümlerinden derlendi. Dataverse açıklamasıyla karşılaştırılmalı.

Veri seti, Braatz'ın TEP kurgusunu (Mod 1, normal çalışma + 20 arıza, 3 dakika örnekleme) her durum için 500 bağımsız koşuya genişletiyor. Eğitim koşuları 500, test koşuları 960 örnek; arıza eğitimde 1. saatte, testte 8. saatte başlıyor.

Veri setinin yapısı

Dosya	Durumlar	Koşu sayısı	Koşu başına örnek (süre)	Arıza başlangıcı	Satır sayısı (hesaplanan)
Fault-free training	0 (normal)	500	500 (25 saat)	yok	250,000
Fault-free testing	0 (normal)	500	960 (48 saat)	yok	480,000
Faulty training	IDV 1-20	20 × 500	500 (25 saat)	1. saat (örnek 20)	5,000,000
Faulty testing	IDV 1-20	20 × 500	960 (48 saat)	8. saat (örnek 160)	9,600,000

- Örnekleme 3 dakika, yani saatte 20 örnek. Test koşularında ilk 160 örnek normal, kalan 800 örnek arızalı ([arXiv 2207.00705](https://arxiv.org/abs/2207.00705)). Eğitimde arızanın 1. saatte (20. örnek) başladığı bilgisi Lomov'dan (bölüm 8).

- Her koşu farklı bir rastgele seed ile üretilmiş ([TimeSeAD belgeleri](#)). Reinartz'a göre (bölüm 4) kurgu Braatz'inkiyle aynı: Mod 1, tam genlik; fark, her durumun 500 kez tekrarlanması.
- Braatz verisinde 21 arıza var; Rieth verisinde IDV 1-20 (sınıf 0-20, toplam 21 sınıf).

Kolonlar

55 kolon ([MathWorks örneği](#)):

Kolon	Ad	İçerik
1	faultNumber	Arıza tipi, 0-20
2	simulationRun	Koşu numarası, 1-500
3	sample	Koşu içindeki örnek numarası
4-44	xmeas_1 - xmeas_41	Ölçülen değişkenler
45-55	xmv_1 - xmv_11	Manipüle edilen değişkenler

Ajitatör hızı (XMV 12) yok; süreç değişkeni sayısı 52. Lomov'un 52 özelliği bu.

Neden önemli

- Braatz verisinde her durum için tek koşu var. Bu, tekrar gerektiren metrikler (ARL, algılama gecikmesinin dağılımı) için yetersiz (Reinartz).
- 500 koşu, eğitim, doğrulama ve test bölmesinin koşu (seed) düzeyinde yapılmasına izin veriyor; aynı koşudan pencereler farklı bölmelere düşmez.

Kullanım notları (ikincil kaynaklardan)

- MathWorks örneği IDV 3, 9 ve 15'i "tanınamaz" gerekçesiyle çıkarıyor; Lomov bu sınıfları tutmuş (sonuçları bölüm 8'de).
- Aynı örnekte koşuların %80'i eğitime, %20'si doğrulamaya ayrılıyor; normalizasyon yalnız eğitim verisinin ortalama ve standart sapmasıyla yapılıyor.

Kaynaklar: [Rieth et al. 2017](#), [Harvard Dataverse \(DOI 10.7910/DVN/6C3JR1; açılmadı\)](#) · [MathWorks, Chemical Process Fault Detection Using Deep Learning](#) · [arXiv 2207.00705](#) · [TimeSeAD, TEP veri seti belgeleri](#)

4. Reinartz et al. (2021): genişletilmiş TEP veri seti

Görev (rehber). Oku: simülasyon kurgusu (çalışma modları, arıza genlikleri, senaryoların çeşitlendirilmesi). Atla: arıza tespit sonuçları (PCA, T^2 ve Q kartları, ARL tabloları).

Veri seti 6 mod $\times$ 28 arıza $\times$ 4 genlik (%25, 50, 75, 100) içeriyor. Her (mod, arıza) çifti için 500 koşu var, toplam 84,000 arıza simülasyonu. Her koşu 100 saat, 3 dakika örneklemeli.

Simülatör ve ayarlar

- Bathelt et al. (2015) revize modelinin değiştirilmiş hali kullanılmış. Simulink modeli Multiloop_mode3: Ricker (1996) dağıtık kontrolü + override döngüleri (Multiloop_mode1 aynı yapının override'sız hali). 6 modun hepsi bununla simüle edilebiliyor.
- Kontrol setpoint'leri sabit değil, basamak veya rampa sinyali olarak üretiliyor; setpoint ve mod değişimleri bu sayede mümkün.
- Model flag = 227: ek ölçümler, rastgele bozucuların iç değerleri ve ölçümlere beyaz Gaussian gürültü açık.
- Revize modeldeki üç önemli değişiklik:
 - Rastgele değişim tipi bozucular açıkken sonuçların çözücüye ve zaman adımına bağımlı olması giderilmiş.
 - Bozucuların genliği ölçeklenebiliyor.
 - 8 yeni rastgele bozucu (IDV 21–28), ek ölçümler ve iç değişkenlerin kaydı eklenmiş.

28 IDV

IDV 1–12 Downs & Vogel ile aynı. Tanımı değişen ya da yeni olanlar:

IDV	Bozucu	Tip
13	Reaksiyon kinetiği	Rastgele değişim (Downs & Vogel'da "yavaş sürüklenme")
14	Reaktör soğutma suyu çıkış vanası	Yapışma
15	Ayırıcı soğutma suyu çıkış vanası	Yapışma
16	Stripper ısı eşanjörü buhar beslemesinin değişim katsayısı	Rastgele değişim
17	Reaktör ısı transferinin değişim katsayısı	Rastgele değişim
18	Kondenser ısı transferinin değişim katsayısı	Rastgele değişim

IDV	Bozucu	Tip
19	Bilinmiyor	Bilinmiyor
20	Bilinmiyor	Rastgele değişim
21	A besleme sıcaklığı (stream 1)	Rastgele değişim
22	E besleme sıcaklığı (stream 3)	Rastgele değişim
23	A besleme debisi (stream 1)	Rastgele değişim
24	D besleme debisi (stream 2)	Rastgele değişim
25	E besleme debisi (stream 3)	Rastgele değişim
26	A + C besleme debisi (stream 4)	Rastgele değişim
27	Reaktör soğutma suyu debisi	Rastgele değişim
28	Kondenser soğutma suyu debisi	Rastgele değişim

Modlar ve kontrol setpoint'leri (Tablo 1-2)

Bu 12 setpoint, kontrol şemasında dışarıdan erişilebilen 12 noktadır; operatörün prosesi etkileyebildiği tek yol. Üretim birimi tabloda yazmıyor; değerler Ricker'ın stream 11 debisiyle (m^3/h) uyumlu.

Setpoint	Mod 1	Mod 2	Mod 3	Mod 4	Mod 5	Mod 6
G/H kütle oranı	50/50	10/90	90/10	50/50	10/90	90/10
Hedef üretim (kg/h)	14,076	14,076	11,111	maksimum	maksimum	maksimum
Üretim setpoint'i	22.89	22.73	18.04	36.04	23.55	20.2
Stripper seviyesi (%)	50	50	50	50	50	50
Ayırıcı seviyesi (%)	50	50	50	50	50	50
Reaktör seviyesi (%)	65	65	65	65	65	65
Reaktör basıncı (kPa)	2800	2800	2800	2800	2800	2800
Ürün mol% G	53.8	11.66	90.09	53.35	11.65	90.07
y_A (%)	63.137	64.196	62.11	61.94	64.03	61.468
y_AC (%)	51	54.24	47.43	58.76	54.32	48.79
Reaktör sıcaklığı (°C)	122.9	124.2	121.9	128.2	124.6	123
Geri dönüş vanası (%)	1	1	77.62	1	1	71.166
Buhar vanası (%)	1	1	1	1	1	1
Ajitatör (%)	100	100	100	100	100	100

Ricker'ın makalede önerdiği değerlerle fark: basınç 2800 kPa (Ricker 2850), reaktör seviyesi %65 (Ricker %55).

Senaryo grupları

Grup	Kurgu	Koşu sayısı
1. Tek arıza	6 mod × 28 IDV × 4 genlik (%25, 50, 75, 100). %100 genlikte 200, diğer her genlikte 100 koşu; seed'ler bağımsız	(Mod, arıza) başına 500; toplam 84,000
2. Setpoint varyasyonu	12 setpoint'in her biri tek başına, orijinal değer ±%15 aralığında %5 adımla. Geçiş profili: basamak veya 10 / 20 / 30 / 40 saatlik rampa	Setpoint başına 7; toplam 504 (6 × 12 × 7)
3. Mod geçişleri	6 mod arasında geçişler, 10 / 20 / 30 / 40 saatlik rampa	Sayı verilmemiş

- Grup 2'nin amacı: işletme koşulu nominal ama biraz değiştiğinde yöntemin yanlış alarm vermemesini test etmek. Yazarlara göre çoğu yöntem tek bir işletme noktasında (Mod 1) eğitildiği için her sapmayı arıza sayıyor. İkinci kullanım: operatöre setpoint önerisi yapan karar destek sistemleri.

- Grup 3, nominal işletme verisini mod geçişleriyle tamamlıyor.
- Grup 2'deki 504 sayısının 5 geçiş profilini içerip içermediği metinden net değil.

Süre ve zaman bölmesi

- Her koşu 100 saat, 3 dakika örnekleme: 2000 gözlem.
- İlk 30 saat (600 gözlem) seçilen modda nominal işletme; 30. saatte arıza ya da setpoint değişikliği başlar.
- 30-40-30 bölmesi: 30 saat nominal, 40 saat geçici (dinamik) yanıt, 30 saat değişmiş koşulda durağan işletme.
- Downs & Vogel setpoint değişikliğinden sonra 24-48 saatlik dinamik davranış öngörüyor. Yazarlar yeni durağan noktaya 40 saat içinde ulaşıldığını gözlemlemiş; basamak tipi arızaların geçici etkisi de 40 saatte yakalanıyor.
- Rastgele değişim ve yapışma tipi bozucular süreci sürekli etkilediği için bunlarda geçici ve durağan yanıt ayırlamıyor.

Veri içeriği

Veri kümesi	İçerik	Kolonlar
processdata	Zaman + 41 XMEAS + 12 XMV (ajitator dahil)	pd(1)-pd(54)
additional_meas	Bathelt'in ek ölçümleri: besleme sıcaklıkları, soğutma suyu giriş sıcaklıkları ve debileri, stream 1-4 kompozisyonları	add(1)-add(32)
idv_monitoring	Rastgele bozucuların gürültüsüz iç değerleri; yalnız IDV 8-13, 16-18, 20-28 aktifken	idv_mon(1)-idv_mon(21)

- Rieth ve Lomov'un 52 özelliği ajitatorü (XMV 12) dışarıda bırakıyor; burada pd(54) olarak var.
- 32 + 21 = 53 ek veri noktası, daha yoğun enstrümantasyonun arıza tespitine etkisini ve bozucuların etkisini ayrıntılı incelemek için eklenmiş.

Depolama ve metadata

- Format HDF5. Hiyerarşi: Mode i → Single fault → {Simulation completed, Simulation stopped}; Setpoint variation; Mode transitions.
- "Simulation stopped" klasörü, arızanın veya setpoint değişikliğinin shutdown'a yol açtığı koşullardır.

- Her koşunun metadata'sı: seed; başlangıç modu (1-6); 3×28 bozucu matrisi (aktivasyondan önceki genlik, sonraki genlik, aktivasyon saati); 3×12 setpoint matrisi (önceki değer, sonraki değer, değişim saati) ve rampa süresi; ortalama işletme maliyeti ve üretim. Her koşu bu bilgiyle yeniden simüle edilebilir.

Önceki veri setleri hakkında (Rieth ayrıntısı: bölüm 3)

- Braatz (Chiang et al. 2000): Mod 1, 21 arıza, her durum tek simülasyon. Eğitim 25 saat (500 gözlem), test 48 saat (960 gözlem), 3 dakika örnekleme.
- Rieth et al. (2017): aynı kurgu, ama her durum bağımsız seed'lerle 500 kez simüle edilmiş. Mod 1, 20 arıza, tam genlik.
- Yazarlar tek koşulu veriyi ARL gibi tekrar gerektiren metrikler için yetersiz buluyor.

5. Bathelt et al. (2015): TEP modelinin revizyonu

Görev (rehber). Oku: orijinal modelde yapılan değişikliklerin listesi. Bozucu genliğinin ayarlanabilirliğiyle ilgili kısım özellikle önemli; README'deki "severity ayarlanamaz" sorununa doğrudan cevap olabilir.

Severity sorusunun cevabı. Revize modelde bozucu genliği ayarlanabiliyor. Bozucu aktivasyon vektörüne 0/1 yerine 0 ile 1 arasında bir değer verildiğinde bozucunun genliği %0-100 aralığında ölçekleniyor (Bölüm 3.2). Bunun için model yapı bayrağının 7. biti (değer 128) açık olmalı. Reinartz'ın kullandığı 227 bayrağı bu biti içeriyor; %25 / 50 / 75 / 100 genlikler bu yolla üretilmiş. Değer 1'i geçemiyor, yani %100'ün üstünde bir genlik verilemiyor.

Sorun: sonuçların çözücüye bağlı olması (Bölüm 2)

- Orijinal kodda (Ricker 2005, C-mex S-function), "rastgele değişim" tipi bozucular açıkken simülasyon sonuçları seçilen çözücüye ve zaman adımına bağlı. Bozucu yokken bu bağımlılık yok.
- Neden: tek bir rastgele sayı üretici hem ölçüm gürültüsü hem süreç bozucuları için kullanılıyor. tefunc() her çağrıldığında üreticinin durumu değişiyor; bu çağrı çıktı hesabında, türev hesabında ve çözücünün iç adımlarında tekrarlanıyor. İç adım sayısı çözücüye göre değiştiği için bozucu polinomları yeniden hesaplanırken üreticinin durumu da çözücüye göre farklı oluyor.
- Downs & Vogel'in tasarımında ana fonksiyon döngü başına bir kez çağrılacaktı; MATLAB/Simulink'in simülasyon döngüsü bu varsayımı bozuyor. Fiziksel-kimyasal model etkilenmiyor: eski sonuçlar geçerli, yalnızca aynı çözücü ayarı olmadan tekrarlanamıyor.

- Örnek (Şekil 1): açık çevrim, Mod 1, reaktör soğutma suyu giriş sıcaklığı ve stream 4 kompozisyonu için rastgele bozucular açık (IDV 11 ve 8). Euler, ode3 ve ode45 belirgin farklı reaktör basıncı ve sıcaklığı veriyor.

Değişiklikler ve yapı bayrağı (Bölüm 3.1–3.2, Tablo 4)

Değişikliklerin çoğu tek bir tamsayı parametreyle açılıp kapanıyor; her bit bir değişikliğe karşılık geliyor.

Bit	Değer	İşlev
0	1	Ek ölçüm noktaları (çıktı 42–73)
1	2	Rastgele bozucuların izleme çıktısı (21 değer)
2	4	Reaksiyon ve süreç izleme çıktısı (62 değer)
3	8	Bileşen konsantrasyonları izleme çıktısı
4	16	Ölçüm gürültüsünü kapatma
5	32	Süreç bozucusu ve ölçüm gürültüsü için ayrı rastgele üreteç durumları
6	64	Bozucuların çözücünden bağımsız hesaplanması (yeniden hesaplama sırası indekse değil zamana göre)
7	128	Bozucuların aktivasyon değerine göre ölçeklenmesi (severity)
15	32768	Ricker (2005) orijinal yapısına dönüş

- Yazarların önerdiği düzeltilmiş bozucu üretimi: $96 = \text{bit } 5 + \text{bit } 6$.
- Reinartz'ın ayarı: $227 = 1 + 2 + 32 + 64 + 128$. Ek ölçümler, bozucu izleme, düzeltilmiş üretim ve genlik ölçekleme açık; bit 4 kapalı olduğu için ölçüm gürültüsü açık.
- Bayraktan bağımsız değişiklikler:
 - `tefunc()` ikiye bölündü: süreç verisi ve çıktılar bir yanda, türevler diğer yanda; simülasyon döngüsündeki konuma göre çağrılıyor. Yalnız bit 15 ile kapatılabilir.
 - Global veri yerine modele özgü bir veri kaydı: aynı Simulink modelinde birden fazla TEP birbirini etkilemeden çalışabiliyor.
 - Rastgele üreticinin başlangıç durumu (seed) parametre olarak veriliyor; 0 dışındaki her tamsayı geçerli.
 - 8 yeni rastgele bozucu (IDV 21–28).

İki model ve parametreleri (Tablo 4)

- **temex_mod**: bozucu aktivasyonu bir parametre dizisi olarak veriliyor.
- **temexd_mod**: bozucu vektörü modelin ek bir girişi; simülasyon sırasında değiştirilebiliyor. Arızayı episode ortasında başlatmak ya da genliği zamanla değiştirmek için bu sürüm gerekiyor.
- Parametreler: 50 durumun başlangıç değerleri (boşsa Downs & Vogel Mod 1); yalnız temex_mod'da bozucu aktivasyon dizisi; seed; yapı bayrağı. Tablo 4 aktivasyon dizisini "20 bozucu" diye tanımlıyor; IDV 21-28'in nasıl etkinleştirildiği kodda kontrol edilmeli.

Yeni bozucular ve izleme çıktısı (Tablo 2 ve 5)

IDV	Bozucu (Bathelt)	İzleme çıktısı
21	A besleme sıcaklığı (stream 1)	°C
22	E besleme sıcaklığı (stream 3)	°C
23	A besleme basıncı (stream 1)	A nominal debisi, kmol/h
24	D besleme basıncı (stream 2)	D nominal debisi, kmol/h
25	E besleme basıncı (stream 3)	E nominal debisi, kmol/h
26	A + C besleme basıncı (stream 4)	A + C nominal debisi, kmol/h
27	Reaktör soğutma suyu devresinde basınç dalgalanması	Reaktör soğutma suyu nominal debisi, m ³ /h
28	Kondenser soğutma suyu devresinde basınç dalgalanması	Kondenser soğutma suyu nominal debisi, m ³ /h

- Nominal debi, ilgili vana %100 açıkken geçecek debi. Reinartz IDV 23-28'i "debi" olarak listeliyor; fiziksel kaynağı basınç dalgalanması.
- Orijinalde "bilinmiyor" olan IDV 16-18 tanımlanmış: 16 stripper ısı eşanjörü buhar beslemesi, 17 reaktör ısı transferi, 18 kondenser ısı transferi (değişim katsayıları). IDV 13 iki reaksiyonun (G ve H) kinetik değişim katsayısı olarak izleniyor. IDV 20 izleniyor ama hala "bilinmiyor"; IDV 19 izleme çıktısında yok.
- İzleme çıktısının 21 değeri: IDV 8 (stream 4'teki A, B, C oranları), 9-12, 13 (iki değer), 16-18, 20 ve 21-28. Reinartz'ın idv_monitoring verisi bu.
- Reaksiyon ve süreç izleme çıktısı (Tablo 3): reaktördeki dönüşüm hızları ve kısmi basınçlar, tüm analizörlerin gecikmesiz ve gürültüsüz değerleri, ölçümlere ve iç değerlere dayalı üretim maliyetleri.

Simülasyon süresi ve zaman adımı (Bölüm 4)

- Düzeltmeden sonra üç çözücü aynı sonucu veriyor (Şekil 4).
- 15 saatlik simülasyon, 250 koşu ortalaması, 1 s adım (Tablo 6): Euler 3.25 $\rightarrow$ 1.84 s, ode3 9.29 $\rightarrow$ 5.09 s, ode45 19.90 $\rightarrow$ 11.54 s. Genel olarak en az %40, ortalama yaklaşık %45 hızlanma. Düzeltilmiş bozucu üretimi ek yük getirmiyor (1.836 ve 1.832 s).
- Daha büyük adımla (Tablo 7): ode3 4 s adımda 2.34 $\rightarrow$ 1.29 s; ode45 en fazla 0.1 saatlik adımda 3.11 $\rightarrow$ 1.83 s.
- Entegrasyon adımı 0.1 saati geçmemeli; kod bu sınırı dayatıyor. Euler için pratik üst sınır 1 s; daha büyük adımda sayısal kararsızlık başlıyor.
- Açık çevrim: Downs & Vogel Mod 1 başlangıç değerleriyle en fazla 3.16 saat sürdürülebiliyor; Ricker'ın (1995) Mod 1 değerleriyle 15 saat.

6. Tobin et al. (2017): domain randomization

Görev (rehber). Oku: yalnızca giriş ve yöntem bölümleri; mantığı anlamak yeterli. Atla: robotik ve görüntü deneyleri.

Fikir: simülatörü gerçeğe yaklaştırmaya çalışmak yerine, simülatörün parametrelerini eğitimde geniş bir aralıkta rastgele değiştirmek. Çeşitlilik yeterince büyükse gerçek dünya, modele eğitimde gördüğü varyasyonlardan biri gibi görünüyor ve ek eğitim gerekmiyor.

Giriş: problem (Bölüm I)

- "Reality gap": simülatör ile gerçek sistem arasındaki farklar. Kaynakları modellenmemiş fizik (esneklik, dişli boşluğu, aşınma, akışkan dinamiği) ve düşük sadakatli sensör modelleri (render'ın gerçek görüntünün zenginliğini ve gürültüsünü üretememesi).
- System identification (simülatörü gerçek sisteme kalibre etmek) zaman alıcı ve hataya açık; iyi yapılırsa bile modellenmemiş etkiler kalıyor.
- Test edilen hipotez: simülasyondaki değişkenlik yeterince büyükse, simülasyonda eğitilen model gerçek dünyaya ek eğitim olmadan genellenir.
- Yaklaşım domain adaptation'dan farklı: gerçek dünyadan veri veya etiket gerekmiyor; istenirse domain adaptation yöntemleriyle birleştirilebiliyor.

Fizik randomizasyonu ile ilgili önceki çalışmalar (Bölüm II.C)

- Mordatch ve ark.: politikayı bir dinamik modeli topluluğu (ensemble) üzerinde eğitmek modelleme hatasına dayanıklılık sağlıyor.
- Sürtünme ve aksiyon gecikmesi randomize edilerek eğitilen bir alet çevirme politikası gerçek robotta çalışmış.

- Yu ve ark. (UP-OSI, bölüm 16): dayanıklılığa güvenmek yerine, değişken fizikle eğitilen bir modelle çevrimiçi system identification.
- Rajeswaran ve ark. (EPOpt): ensemble'dan öğrenme için adversarial eğitim ve hedef alandan gelen veriyle ensemble dağılımını uyarlama.

Yöntem (Bölüm III)

- Görev: tek bir kamera görüntüsünden nesnelerin (x, y, z) konumunu tahmin eden bir dedektör.
- Her eğitim örneğinde rastgele değiştirilenler:
 - masadaki dikkat dağıtıcı nesnelerin sayısı (0–10) ve şekli
 - tüm nesnelerin konumu ve dokusu
 - masa, zemin, arka plan ve robotun dokusu
 - kameranın konumu (başlangıç noktası etrafında $10 \times 5 \times 10$ cm kutu), bakış açısı (± 0.1 rad) ve görüş alanı ($\pm 5\%$)
 - ışık sayısı, konumu, yönü ve parlama özellikleri
 - görüntüye eklenen gürültünün tipi ve miktarı
- Dokular bilinçli olarak gerçekçi değil: rastgele bir RGB rengi, iki renk arası gradyan veya dama deseni. Dedektör nesnenin rengini hiç görmüyor, yalnız boyutunu ve şeklini.
- Kamera kalibre edilmiyor; kalibrasyon yerine kamera parametreleri randomize ediliyor. Yani belirsiz olan parametre ölçülüyor, eğitimde değiştiriliyor.
- Model: VGG-16 tabanlı CNN, tam bağlantılı katmanlar 256 ve 64, dropout yok; L2 kaybı, Adam, lr yaklaşık $1e-4$.

Atlanan deneylerden tek not

Ablation'da belirleyici faktör çeşitlilik miktarı: 1000'den az farklı doku kullanıldığında gerçek dünyadaki performans belirgin düşüyor. Ayrıntılar görev gereği atlandı.

7. Ni et al. (2022): recurrent model-free RL, öncelikli

Görev (rehber). Oku: tasarım seçimlerinin tartışıldığı yöntem bölümü (encoder paylaşımı, geçmiş uzunluğu, RNN'e verilen girdiler) ve karşılaştırma grafikleri. Ara: sonucu gerçekten değiştiren ablation deneyleri.

Ara'nın cevabı. Sonucu en çok değiştiren üç karar var. Birincisi actor ve critic için ayrı RNN encoder kullanmak; paylaşılan encoder hiç öğrenemiyor. İkincisi RL algoritması: ortama göre 6.8 kata kadar fark. Üçüncüsü bağlam uzunluğu: optimum göreve özgü, 2.2 kata kadar fark. Girdi seçimi orta, LSTM/GRU seçimi küçük etkili.

Beş tasarım kararı

Karar	Seçenekler	Bulgu
Arch: actor ve critic RNN encoder'ı paylaşsın mı	shared / separate	Shared, Semi-Circle ve Pendulum-V'de hiç öğrenemedi. Critic kaybının gradyanı paylaşılan encoder'ı domine ediyor (gradyan normları farklı ölçekte). Separate öneriliyor.
Inputs: RNN'e ne verilir	o, oa, or, oar, oard (o gözlem, a önceki aksiyon, r ödül, d done)	Girdi, gizli durumu çıkarmaya yetecek bilgiyi taşımali. Önceki ödülü eklemek gizli hız bilgisini açığa çıkarıyor.
RL: temel algoritma	TD3, SAC (ayrık aksiyonda SAC-Discrete)	Off-policy algoritmalar genelde on-policy'den iyi. TD3, 5 benchmark'ın 4'ünde en iyi; zor dinamikli ortamlarda (Ant, Humanoid) SAC daha iyi.
Encoder	LSTM, GRU	Genelde anlamlı fark yok.
Len: eğitimde RNN'e verilen dizi uzunluğu	kısa 5, orta 64, uzun >100 (veya tüm episode)	Optimum göreve özgü. En iyi varyantların çoğunda 64; başlangıç için iyi bir seçim.

Ablation: tek faktör değişince (Tablo 3)

Her satırda, o benchmark'ın en iyi varyantından tek bir karar değiştirilmiş; farkın en büyük olduğu ortam seçilmiş.

Değişiklik	Alan, ortam	Önce → sonra
Inputs: oa → oar	Standart POMDP, Walker-P	981.6 → 1345.0 (1.3×)
RL: TD3 → SAC	Standart POMDP, Ant-P	310.7 → 2123.5 (6.8×)
Encoder: LSTM → GRU	Robust RL, Walker-Robust (en kötü getiri)	765.9 → 931.3 (1.2×)

Değişiklik	Alan, ortam	Önce → sonra
Len: 64 → 400	Meta-RL, Cheetah-Vel	-85.2 → -74.6 (+%14)
Len: 64 → 5	Genelleme, Hopper-Generalize (ekstrapolasyon başarısı)	0.292 → 0.415 (1.4×)
Len: 64 → 5	Standart POMDP, Walker-V	121.4 → 264.3 (2.2×)

Tek faktör grafiklerinden (Ek E.2) ek gözlemler:

- Hızın gizli olduğu "-P" ortamlarında (Ant-P, Hopper-P, Walker-P) Len 64, Len 5'ten belirgin iyi.
- Cheetah-Vel'de (görev parametresi = hedef hız) Len 5 neredeyse hiç öğrenemiyor; 64 ve 400 iyi.
- RL seçimi Ant-P, Cheetah-V, Wind ve Hopper-Generalize'da belirleyici.
- Girdi seçimi çoğu "-P" ortamında fark yaratıyor; olası neden, "oar" girdisinin eksik hız bilgisini taşıması.

Benchmark başına en iyi tek varyant (Tablo 2 ve 7)

Alan (benchmark)	Arch	Encoder	Inputs	Len	RL
Meta-RL (off-policy variBAD ortamları)	separate	LSTM	oard (ortama göre ord, oad)	64	TD3
Meta-RL (on-policy variBAD ortamları)	separate	GRU	oard	tüm episode	SAC
Standart POMDP (VRM)	separate	GRU	oa	64	TD3
Robust RL (MRPO)	separate	LSTM	o	64	TD3
RL'de genelleme (SunBlaze)	separate	LSTM	o	64	TD3
Zamansal kredi ataması	separate	LSTM	o	tüm episode	SAC-Discrete

Gizli durumun dinamikte olduğu ve episode içinde sabit kaldığı robust ve genelleme kurgularında kazanan aynı: td3-lstm-64-o-separate. TEP arızalarına kavramsal olarak en yakın satırlar bunlar.

POMDP alt alanları (Tablo 1, özet)

Alan	Gizli durum dinamikte	Gizli durum ödülde	Episode içinde sabit	Tipik girdi
Standart POMDP	evet	evet	hayır	oar
Meta-RL	genelde hayır	evet	evet	oard
Robust RL	evet	genelde hayır	evet	oa
RL'de genelleme	evet	genelde hayır	evet	oa
Zamansal kredi ataması	hayır	evet	hayır	oa

Mimari ve eğitim detayı (Şekil 7, Tablo 5)

- Actor: gözlem embedder'ı A, önceki aksiyon embedder'ı ve ödül embedder'ı $\rightarrow$ RNN $\rightarrow$ MLP $\rightarrow$ a_t. Güncel gözlem ayrıca embedder B ile RNN'i atlayıp doğrudan MLP'ye gider (shortcut); RNN'in güncel gözlemi ezberleme yükünü azaltır.
- Critic: ayrı bir RNN; gözlem-aksiyon embedder'ı ve iki Q başlığı.
- Embedder'lar 1 gizli katman, RNN tek katman LSTM veya GRU, MLP'ler 2 gizli katman.
- Boyutlar (benchmark'a göre değişir): gözlem embedder'ı 32, aksiyon 16, ödül 16, RNN 128; MLP [128, 128, 128] (meta-RL) veya [256, 256].
- Eğitim: Adam, lr 3e-4; γ 0.99; τ 0.005; replay buffer 1e6; batch 32-64; RNN ağırlıkları ortogonal başlatılır.
- Replay: bağlam uzunluğunda alt-yörüngeler örneklenir. Episode bağlamdan kısaysa sıfırla doldurulup maskelenir. RNN başlangıç durumu sıfır.
- Bellek dostu replay: geçişler 2 boyutlu tutulur (geçiş sayısı $\times$ gözlem boyutu), episode sonları kaydedilir, maskeler örneklerken üretilir. VRM'ye göre 200 kat daha az RAM.
- Değerlendirme: 4 seed; nihai performans son %20 ortam adımının ortalaması; normalize getiri $(R - R_{\min}) / (R_{\max} - R_{\min})$, oracle ve random dahil.

8. Lomov et al. (2021): TEP'te zamansal derin öğrenme

Görev (rehber). Oku: veri hazırlama (pencere nasıl kesiliyor, normalizasyon nasıl yapılıyor) ve pencere uzunluğunu karşılaştıran sonuç tabloları. Atla: modellerin mimari detayları.

Makalede doğrudan "pencere uzunluğu $\rightarrow$ doğruluk" tablosu yok. Karşılaştırma iki değerlendirme uzunluğu arasında: arıza başlangıcından sonraki ilk 60 adım (3 saat) ve tüm 800 adım (40 saat). 60 adımda normal durum ve IDV 15 belirgin zayıf, tam uzunlukta

neredeyse tüm sınıflar 1.0'a çıkıyor.

Veri

- Rieth et al. (2017) genişletilmiş TEP verisi. Mod 1; 21 sınıf (0 normal, 1–20 arıza), dengeli çok sınıflı sınıflandırma. Zor sınıflar (3, 9, 15) da tutulmuş.
- 52 özellik: 41 XMEAS + 11 XMV (ajitator yok), 3 dakika örnekleme.
- Eğitim koşulları 500 adım (25 saat), arıza 1. saatte (20. adım) başlıyor. Test koşulları 960 adım (48 saat), arıza 8. saatte (160. adım) başlıyor; arıza sonrası 800 adım kalıyor.
- Makale "örnek" ile "simülasyon koşusu"nu karıştırıyor. Reinartz'a göre Rieth'te her durum için 500 bağımsız koşu, koşu başına 500 / 960 gözlem var.

Normalizasyon

- Her boyut ayrı ayrı standart ölçekleniyor (z-score): $\hat{x} = (x - \text{ortalama}_i) / \text{std}_i$.
- Eksik değer olmadığı için doldurma yapılmamış.
- Ortalama ve standart sapmanın hangi veriden (yalnız eğitim mi, tümü mü) hesaplandığı yazmıyor.

Pencere kesme

Model grubu	Pencere	Etiket
RNN "type 1" (GRU, LSTM, $\pm$ attention, Transformer)	Koşunun başından başlayan örnekler: 5, 25, 50, 100, 250 adım	Önek başına tek sınıf (koşunun sınıfı)
RNN "type 2" (seq2seq)	Sabit 200 adım; kaynak diziler ikiye bölünerek elde ediliyor	Her adımda sınıf; tek yönlü RNN, gelecek bilgi sızmasın diye
Temporal CNN1D ve CNN1D2D	Simülasyonun belli bir noktasında biten sabit uzunluklu kesitler, çoğunlukla 60 adım; epoch başına koşu başına 500 kesit	Tek sınıf
GAN diskriminatörü	[64, 500, 52] tensörleri: batch 64, 500 adım, 52 özellik	Gerçek/sahte + 21 sınıf

- Eğitim: RNN'ler 100 epoch, CNN'ler 40 epoch; Adam, lr 1e-3, ReduceLROnPlateau, batch 64; en iyi epoch'un ağırlıkları.

- Type 1'in gerekçesi: kısa örneklerle eğitmek, modelin erken (az veriyle) tahmin yapmasını sağlıyor ve uzun dizilerde gradyan sorunlarını azaltıyor.

Sonuçlar: 60 adım ve tüm adımlar (TPR, Tablo 3-4)

Hücreler "60 adım / tüm 800 adım" TPR'si. FPR, normal sınıf dışında hemen hep ≤ 0.03 .

Sınıf	GRU t1	LSTM t1	GRU+att t1	LSTM+att t1	Transformer	GRU t2	LSTM t2
0 (normal)	0.61 / 0.83	0.71 / 0.81	0.64 / 0.75	0.66 / 0.94	0.47 / 0.67	0.79 / 1.00	0.86 / 0.99
3	0.94 / 1.00	0.92 / 1.00	0.95 / 1.00	0.95 / 1.00	0.95 / 1.00	0.96 / 1.00	0.96 / 1.00
9	0.86 / 1.00	0.90 / 1.00	0.86 / 1.00	0.88 / 1.00	0.55 / 0.70	0.92 / 1.00	0.81 / 1.00
13	0.89 / 1.00	0.91 / 0.98	0.92 / 0.99	0.93 / 0.97	0.87 / 0.95	0.92 / 0.99	0.93 / 0.96
15	0.67 / 0.93	0.27 / 0.40	0.68 / 1.00	0.70 / 0.98	0.61 / 0.81	0.58 / 0.94	0.41 / 0.89
18	0.73 / 1.00	0.74 / 1.00	0.73 / 1.00	0.73 / 1.00	0.71 / 0.79	0.75 / 1.00	0.74 / 1.00
20	0.89 / 1.00	0.89 / 1.00	0.90 / 1.00	0.91 / 1.00	0.87 / 1.00	0.89 / 1.00	0.88 / 1.00

Diğer sınıflar 60 adımda da yüksek: 10 ve 17 için 0.93–0.99, geri kalanlar 1.00. Tam uzunlukta Transformer dışındaki modellerde hemen hepsi 0.94–1.00.

İkili sınıflandırma, normal ve arıza (Tablo 5-6). Arıza sınıfı için FPR / TPR:

Model	60 adım	Tüm adımlar
GRU t1	0.39 / 0.97	0.17 / 1.00
LSTM t1	0.29 / 0.95	0.19 / 0.97
GRU+att t1	0.36 / 0.97	0.25 / 1.00
LSTM+att t1	0.34 / 0.97	0.06 / 1.00
Transformer	0.53 / 0.97	0.33 / 0.98
GRU t2	0.21 / 0.96	0.00 / 1.00
LSTM t2	0.14 / 0.94	0.01 / 0.99

Kısa pencerede yanlış alarm oranı yüksek. Normal durumu arızadan ayırmak, arızaları birbirinden ayırmaktan daha fazla bağlam istiyor.

Algılama gecikmesi (Tablo 2; 1 adım = 3 dk)

Gecikme yalnız doğru sınıflanan koşullar üzerinden ölçülmüş. Aralıklar 7 model arasındaki en düşük ve en yüksek değerler.

Grup	Sınıflar ve gecikme (adım)
Hızlı (≤ 4)	1: 1.7–2.9 · 4: 1.0–3.7 · 5: 1.0–3.5 · 6: 1.0–2.1 · 7: 1.0–2.3 · 14: 1.6–2.7
Orta (3–12)	2: 5.3–11.4 · 3: 3.5–6.9 · 11: 5.2–7.1 · 12: 6.2–7.4 · 19: 3.1–6.4
Yavaş (10–26)	8: 15.6–17.9 · 9: 10.5–22.9 · 10: 21.5–25.6 · 16: 11.9–13.6
Çok yavaş (28–46)	13: 31.1–36.1 · 17: 28.0–30.5 · 18: 37.6–45.8 · 20: 29.9–38.0
Modele çok bağlı	15: 8.0 (LSTM+att) – 56.5 (LSTM t2)
Normal	0: 5.3–26.3

Yazarlar en kötü gecikme yaklaşık 56.5 adım olduğu için 60 adımlık değerlendirme penceresini seçmiş.

Dikkat edilecekler

- Type 1 örnekleri koşunun başından başlıyor, eğitimde arıza ise 20. adımda başlıyor. Bu yüzden 5 adımlık örnekler tamamen arıza öncesi veri olduğu halde arıza etiketi taşıyor; 25 adımlıklarda yalnız 5 adım arıza sonrası. Makale bunu tartışmıyor.
- Pencere uzunluğunun etkisi ayrı bir ablation olarak raporlanmamış; eğitimde farklı uzunluklar karışık kullanılmış.

9. Tallec et al. (2019): zaman ayırklaştırmasına dayanıklı Q-learning

Görev (rehber). Oku: giriş bölümü ve Δt küçüldükçe ne olduğunu gösteren deney grafikleri. Atla: teorik ispatlar.

Δt küçüldükçe tek bir aksiyonun getiriye etkisi de küçülüyor; $Q(s, a)$ aksiyondan bağımsız hale gelip $V(s)$ 'ye çöküyor. DQN ve DDPG küçük Δt 'de bu yüzden bozuluyor. Önerilen çözüm Q 'yu V ve ölçeklenmiş avantaj olarak ayırmak (Deep Advantage Updating, DAU).

Giriş: problem (Bölüm 1)

- Çoğu kontrol ortamı sürekli bir sistemin ayırklaştırılmış hali. Δt 'yi simülatör adımı, kare hızı ya da aktüatör ve sensör frekansı belirliyor. Prensipde Δt 'yi küçültmek (daha sık karar) performansı yalnızca artırmalı.

- Gerçekte Q-learning tabanlı yöntemler (DQN, DDPG) Δt değişimine hiç dayanıklı değil. Sezgi: $Q^*(s, a)$, a aksiyonunu uygulayıp sonra optimal davranmanın değeri. a çok kısa süre uygulanırsa diğer aksiyonlara üstünlüğü de çok küçük kalıyor; bu, γ uygun şekilde ölçeklense bile geçerli.
- $\Delta t \rightarrow 0$ limitinde her aksiyonun etkisi kayboluyor: sürekli zamanda Q fonksiyonu yok (Teorem 2, ispat atlandı).
- Sorun ortamda tek bir zaman ölçeği olsa bile ortaya çıkıyor; çok ölçekli RL'den farklı, süreklilikten gelen bir etki. Algoritmanın zaman ölçeği ile fiziksel sistemin zaman ölçeği arasındaki uyumsuzluk olarak da görülebilir.
- On-policy yöntemler (A3C, PPO, TRPO) kapsam dışı bırakılmış.

Ölçekleme kuralları (Bölüm 3)

$$\gamma_{\Delta t} = \gamma^{\Delta t}, \quad r_{\Delta t} = \Delta t \cdot r, \quad Q^{\pi}_{\Delta t}(s, a) = V^{\pi}_{\Delta t}(s) + O(\Delta t)$$

- $\gamma_{\Delta t} = \gamma^{\Delta t}$, fiziksel zamandaki ufku sabit tutmak için. Ufuk yaklaşık $1/(1 - \gamma)$ fiziksel zaman birimi oluyor. γ adım başına sabit bırakılırsa fiziksel ufuk $\Delta t/(1 - \gamma)$ olur ve Δt küçüldükçe ajan giderek kısa görüşlü hale gelir.
- Fiziksel zaman t ile algoritmik zaman k (adım sayısı) arasında $t = k \cdot \Delta t$.

DAU: önerilen algoritma (Bölüm 4)

$$Q_{\theta}(s, a) = V_{\theta}(s) + \Delta t \cdot A_{\psi}(s, a), \quad A_{\psi}(s, a) = \bar{A}_{\psi}(s, a) - \bar{A}_{\psi}(s, \pi(s))$$

- $A = (Q - V)/\Delta t$, ölçeklenmiş avantaj. $\Delta t \rightarrow 0$ 'da aksiyon bilgisini koruyan bir limite gidiyor. İkinci eşitlik $A(s, \pi(s)) = 0$ tutarlılık koşulunu otomatik sağlıyor.
- Keşif: ϵ -greedy, küçük Δt 'de rastgeleliği ortalayıp deterministik bir politikaya çöküyor (Teorem 4). Sürekli aksiyonda aksiyona, ayrık aksiyonda avantajlara eklenen Ornstein-Uhlenbeck gürültüsü kullanılmalı.
- Öğrenme oranları Δt ile orantılı olmalı ($\eta = \alpha \cdot \Delta t$). Δt 1'den büyükse parametreler başlangıç değerinde kalıyor, küçükse ıraksayabiliyor (Teorem 5).

Deneyler: Δt küçüldükçe ne oluyor (Şekil 1-2)

Test edilen Δt aralıkları (saniye): Pendulum ve Cartpole 0.01-0.0005, Bipedal Walker 0.01-0.001, Ant ve Half-Cheetah 0.05-0.002. Getiriler Δt ile ölçeklenmiş; eğitim süresi adım sayısı olarak değil fiziksel zaman olarak gösteriliyor. Aşağıdaki sayılar grafikten yaklaşık okundu.

- **Şekil 1, Pendulum değer fonksiyonu:** DAU'nun öğrendiği değer fonksiyonu tüm Δt 'lerde birkaç dakikalık fiziksel eğitimden sonra aynı yapıya ulaşıyor. DDPG'ninki Δt 'ye göre çok farklı; $\Delta t = 0.005$ ve 0.0005 'te ilk dakikalarda neredeyse bilgi taşıyor.
- **Şekil 2, öğrenme eğrileri:**
 - Pendulum: iki yöntem de yakınsıyor; küçük Δt 'de DDPG çok daha oynak.
 - Bipedal Walker: DAU tüm Δt 'lerde yaklaşık 100–150 getiriye ulaşıyor, DDPG 0 civarında kalıyor.
 - Ant: DAU tüm Δt 'lerde pozitif (yaklaşık 1000–3000); DDPG'nin performansı Δt küçüldükçe düşüyor ve en küçük Δt 'lerde negatife iniyor.
 - Half-Cheetah: Δt küçüldükçe DDPG kötüleşiyor; DAU da tam değişmez değil. Yazarlar bunu değer fonksiyonundaki süreksizliklere (baş üstü ya da sırt üstü yürüme gibi alt-optimal rejimler) bağlıyor.
 - Cartpole: gürültü baskın, yorumlamak zor.
- Karşılaştırmada DDPG ve DQN'e de $\gamma^{\delta t}$ verilmiş; gerçekleştirme ayrıntıları eke bırakılmış.

Tartışmadaki uyarılar (Bölüm 6)

- Algoritma Δt 'nin bilinmesini gerektiriyor (simülatör adımı, kare hızı vb.).
- Sabit boyutlu bir replay buffer, Δt değişince fiziksel zamanda farklı bir süreyi kapsıyor; tam değişmezlik için buffer boyutu $1/\delta t$ ile ölçeklenmeli.
- Recurrent bir model kullanılıyorsa, belleğin $\Delta t \rightarrow 0$ 'da da fiziksel zamanda sonlu bir süreyi koruyabilmesi gerekiyor.

10. Mamba (Gu & Dao, 2023): seçici durum-uzayı modeli

Görev (rehber). Oku: seçici SSM fikrinin sezgisel açıklaması (yöntem bölümünün başı) ve uzun dizi deneyleri (selective copying ve benzerleri). Atla: donanım ve GPU kernel optimizasyonu (Bölüm 3.3).

Mamba, SSM'nin Δ , B ve C parametrelerini girdiye bağlı hale getiriyor. Böylece model hangi girdiyi duruma alıp hangisini yok sayacağını içeriğe göre seçebiliyor; sabit dinamikli (LTI) modeller bunu yapamıyor.

Arka plan: yapısal SSM (Bölüm 2)

$$h'(t) = A h(t) + B x(t), \quad y(t) = C h(t) \quad \Longleftrightarrow \quad h_t = \bar{A} h_{t-1} + \bar{B} x_t, \quad y_t = C h_t, \quad \bar{A} = \exp(\Delta A)$$

- Sürekli bir sistem Δ adımıyla ayrıklaştırılıyor (zero-order hold). Klasik SSM'ler (S4) doğrusal ve zamanla değişmez: Δ , A, B, C her adımda aynı. Bu sayede evrişim (convolution) olarak hızlı eğitilebiliyor, çıkarımda ise RNN gibi adım adım çalışıyor.
- Her girdi kanalı ayrı işleniyor; kanal başına N boyutlu gizli durum (örneğin N = 16), A köşegen.

Seçicilik fikri (Bölüm 3.1, 3.2 ve 3.5)

- Dizi modellemenin temel sorunu bağlamı küçük bir duruma sıkıştırmak. Attention hiç sıkıştırmıyor: etkili ama yavaş. RNN sabit boyutlu bir durum tutuyor: hızlı ama etkinliği durumun bağlamı ne kadar iyi sıkıştırdığıyla sınırlı.
- LTI modellerin başarısız olduğu iki sentetik görev:
 - **Selective Copying:** hatırlanacak token'lar arasındaki boşluk rastgele. Yalnız zamanı sayarak çözülüyor, içeriğe bakmak gerekiyor. (Boşlukların sabit olduğu klasik Copying görevi LTI modellerle kolayca çözülüyor.)
 - **Induction Heads:** bağlamda "A B" görüldüyse, A tekrar geldiğinde B'yi üretmek (çağrışımsal hatırlama).
- Çözüm: Δ , B ve C'yi girdinin doğrusal izdüşümünden üretmek (Algoritma 2). Model artık zamanla değişen bir özyineleme; evrişim yerine paralel tarama (scan) ile hesaplanıyor.
- **Δ 'nın yorumu:** büyük Δ durumu sıfırlayıp güncel girdiye odaklanıyor, küçük Δ durumu koruyup girdiyi yok sayıyor. N = 1, A = -1, B = 1 alınınca seçici SSM klasik RNN kapısına (gating) indirgeniyor (Teorem 1):

$$g_t = \sigma(\text{Linear}(x_t)), \quad h_t = (1 - g_t)h_{t-1} + g_tx_t$$

- **B ve C'nin yorumu:** girdinin duruma girip girmeyeceğini ve durumun çıktıya geçip geçmeyeceğini içeriğe göre ayarlıyor. A'yı ayrıca seçici yapmak gereksiz; A modele yalnız Δ üzerinden etki ediyor.
- Seçici modellerin üç mekanik etkisi:
 - **Değişken aralık:** ilgili girdiler arasındaki gürültüyü filtreleme.
 - **Bağlam filtreleme:** çoğu dizi modeli daha uzun bağlamla iyileşmiyor, çünkü alakasız geçmiş yok saymıyor. Seçici model durumunu istediği an sıfırlayabildiği için performansı prensipte bağlam uzadıkça monoton artıyor.
 - **Sınır sıfırlama:** birleştirilmiş bağımsız diziler arasında (örneğin RL'de episode sınırları) durumu sıfırlayabiliyor; LTI modeller bilgiyi diziler arasında sızdırıyor.

Uzun dizi deneyleri (Bölüm 4.1, 4.3.2, 4.4.1)

Selective Copying (Tablo 1): dizi uzunluğu 4096, 16 veri token'ı, 2 katman, D = 64.

Mimari	İç katman	Doğruluk (%)
Mamba	S6 (seçici)	99.8
H3	S6	99.7
Kapısız	S6	97.0
H3	S4	57.0
Mamba	S4	56.4
H3	Hyena	30.1
Mamba	Hyena	28.4
Kapısız	S4	18.3

Kapılı mimari (H3, Mamba bloğu) tek başına kısmi iyileşme sağlıyor; farkı yaratan seçici katman (S6). Yazarlara göre mimari kapılar dizi eksenini boyunca etkileşmediği için seçicilik sayılmaz.

Induction Heads (Tablo 2 ve 11): 256 uzunlukta eğitim, 64 ile 1,048,576 arası test. Değerler test doğruluğu (%).

Model	Parametre	512 (2×)	1024 (4×)	16,384 (64×)	1,048,576 (4096×)
Mamba	74K	100	100	100	100
MHA-xPos	137K	99.6	67.6	7.8	bellekle yetmedi
MHA-RoPE	137K	83.6	31.3	5.5	bellekle yetmedi
MHA-Abs	137K	58.6	26.6	7.8	bellekle yetmedi
Hyena	69M	100	44.1	7.0	9.8
H3	153K	80.9	39.5	5.9	7.4

- Mamba, eğitimde gördüğünün 4000 katı uzunluğa kusursuz genelleniyor; diğerleri 2 katın ötesine geçemiyor.
- **DNA, bağlam uzunluğu (Bölüm 4.3.2):** 1K'dan 1M'a kadar bağlam uzadıkça Mamba'nın perplexity'si iyileşiyor, LTI tabanlı HyenaDNA'nınki kötüleşiyor. Yazarların açıklaması: çok uzun bir evrişim çekirdeği uzun ve gürültülü dizinin tamamını toplayıp ortalıyor.
- **Ses, bağlam uzunluğu (Bölüm 4.4.1):** 8K'dan yaklaşık 1M örneğe kadar Mamba ve SaShiMi (S4 tabanlı) ikisi de iyileşiyor; Mamba her uzunlukta daha iyi ve fark uzun bağlamda açılıyor. Bu deneyde gerçel yerine karmaşık sayılı parametrisasyon kullanılmış.

Sınırlama: sürekli sinyaller (Bölüm 5, Ek E.4)

- Seçicilik ayrık verilerde (metin, DNA) LTI'nın zayıflığını gideriyor, ama LTI'nın iyi olduğu verilerde performansı düşürebiliyor.
- Uzun ses dalga formlarında S4'ten S6'ya geçiş performansı belirgin kötüleştirilmiş (Şekil 10). Yazarların yorumu: düzenli örneklenmiş ve pürüzsüz sinyaller, aynı tümevarımsal önyargıya sahip sürekli LTI modellerden yararlanıyor.

Ablation notları (Tablo 9–10, dil modeli)

- En büyük kazanç Δ 'yı seçici yapmaktan geliyor; Δ izdüşümü 1 boyutlu olsa bile perplexity $9.12 \rightarrow 8.97$.
- Durum boyutunu $N = 1$ 'den 16'ya çıkarmak yalnız B ve C seçiciyse belirgin fayda sağlıyor ($9.73 \rightarrow 8.71$); sabit B ve C ile neredeyse etkisiz ($9.88 \rightarrow 9.81$).

11. Zeng et al. (2023): lookback window uzunluğu

Görev (rehber). Oku: lookback window uzunluğunu değiştiren deney ve ilgili grafik. Makalenin geri kalanı gerekmez.

Pencere uzadıkça basit doğrusal model (LTSF-Linear) düzenli olarak iyileşiyor; Transformer tabanlı modellerin hatası ise sabit kalıyor ya da artıyor. Yazarlara göre Transformer'lar uzun girdide zamansal bilgi yerine zamansal gürültüye uyum sağlıyor.

Deney kurgusu (Bölüm 5.3, Ek C.2)

- Görev: uzun vadeli zaman serisi tahmini, $T = 720$ adım ileri.
- Lookback $L \in \{24, 48, 72, 96, 120, 144, 168, 192, 336, 504, 672, 720\}$. Saatlik verilerde bu 1–30 gün. 5 dakikalık ETTm verisinde $L \in \{24, 36, 48, 60, 72, 144, 288\}$, yani 2–24 saat; 10 dakikalık Weather'da 4–120 saat.
- Karşılaştırılanlar: Transformer, Informer, Autoformer, Pyraformer, FEDformer ve üç doğrusal model.
- LTSF-Linear zaman ekseninde tek bir doğrusal katman: $\hat{X} = W X$, $W \in \mathbb{R}^{(T \times L)}$. Ağırlıklar değişkenler arasında paylaşıyor; değişkenler arası korelasyon modellenmiyor. NLinear dizinin son değerini çıkarıp tahmine geri ekliyor (dağılım kaymasına karşı); DLinear trend ve mevsimsel bileşeni ayırıp ayrı doğrusal katmanlarla işliyor.

Sonuç (Şekil 4, $T = 720$)

Değerler MSE, şekilden yaklaşık okundu.

Veri seti ve model	L = 24	L = 96	L = 336	L = 720
Traffic, Linear	~0.90	~0.65	~0.47	~0.45
Traffic, FEDformer	~0.66	~0.64	~0.63	~0.62
Traffic, Informer	~0.96	~1.03	~1.40	~1.47
Electricity, Linear	~0.31	~0.25	~0.21	~0.20
Electricity, FEDformer	~0.25	~0.25	~0.25	~0.31
Electricity, Informer	~0.35	~0.39	~0.42	~0.42

- Doğrusal modellerin üçü de L büyüdükçe belirgin iyileşiyor; kazanç L = 336'dan sonra büyük ölçüde doyuyor. Traffic'te Linear, FEDformer'ı L $\approx$ 96–120 civarında geçiyor.
- Transformer'ların hatası sabit kalıyor ya da artıyor. Yazarların yorumu: 96 adımlık girdi çoğu Transformer için tam uygun; daha uzun girdi bu modellere fayda sağlamıyor.
- Ek C.2: veri setlerinin çoğunda (örneğin ETTm1, Traffic) aynı desen. Exchange-Rate'te uzun pencere doğrusal modele de fayda sağlamıyor; yazarlar bunu dağılım kaymasına bağlıyor.

Pencereyle ilgili iki destekleyici deney (kısaca)

- **Yakın ve uzak girdi (Tablo 3):** aynı 720 adımı, hemen önceki 96 adım yerine 96 adım daha eski bir pencereden tahmin etmek FEDformer'ı yalnız hafif kötüleştiriyor (Electricity 0.251 $\rightarrow$ 0.265, Traffic 0.631 $\rightarrow$ 0.645). Transformer'lar yalnız yakın geçmişten benzer bilgi çekiyor.
- **Girdi sırasını karıştırma (Tablo 5):** Linear'ın hatası belirgin artıyor (Exchange'de ortalama %27), Transformer'ları neredeyse değişmiyor. Self-attention sıra bilgisini kullanmıyor; zaman serisinde sıra, taşınan bilginin kendisi.

12. PEARL (Rakelly et al., ICML 2019): olasılıksal context değişkeni

Görev (rehber). Oku: context encoder bölümü (geçmişten latent vektörün nasıl çıkarıldığı). Ara: appendix'teki hiperparametre tablosu ve latent boyutu.

Ara'nın cevabı. Gönderilen sürümde (arXiv v1, 11 sayfa) hiperparametre tablosu yok. Appendix yalnız ortam listesi ve uzun eksenli grafikleri içeriyor; latent boyutu makalenin hiçbir yerinde yazmıyor. Değeri yazarların resmi kodundan aldım ([oyster](#), [configs/default.py](#)): latent_size = 5.

Context encoder (Bölüm 4.1)

- Bağlam c , o görevde toplanan geçişlerin kümesi: $c_n = (s_n, a_n, r_n, s'_n)$. Encoder bir çıkarım ağı: $q_\phi(z | c)$, posterior $p(z | c)$ 'yi tahmin ediyor.
- Encoder permütasyon-değişmez. Gerekçe: tam gözlenen bir MDP'de görevi anlamak için geçişlerin sırası önemsiz. Posterior, her geçişten gelen bağımsız Gaussian faktörlerin çarpımı (Denklem 2):

$$q_\phi(z | c_{1:N}) \propto \prod_{n=1}^N \Psi_\phi(z | c_n), \quad \Psi_\phi(z | c_n) = \mathcal{N}(f_\mu^\phi(c_n), f_\sigma^\phi(c_n))$$

- f_ϕ her geçiş için μ ve σ üreten bir MLP (Şekil 1). Gaussian'ların çarpımı yine Gaussian, bu yüzden posterior kapalı formda hesaplanıyor.
- Amaç fonksiyonu (Denklem 1); $p(z)$ birim Gaussian prior:

$$\mathbb{E}_{\mathcal{T}} \left[\mathbb{E}_{z \sim q_\phi(z | c^\mathcal{T})} [R(\mathcal{T}, z) + \beta, D_{KL}(q_\phi(z | c^\mathcal{T}) || p(z))] \right]$$

- KL terimi bir bilgi darboğazı (information bottleneck) gibi çalışıyor: z yalnız göreve uyum için gereken bilgiyi taşıyor, eğitim görevlerine aşırı uyum azalıyor.
- $R(\mathcal{T}, z)$ için üç seçenek tartışılıyor: MDP'yi yeniden kurmak (ödül ve dinamik tahmini), Q fonksiyonunu modellemek, getiriye maksimize etmek. En iyi sonucu encoder'ı critic'in Bellman kaybıyla eğitmek vermiş; actor getirisi ve durum/ödül yeniden kurma daha kötü. CaDM'den temel fark bu: CaDM encoder'ı dinamik tahmin kaybıyla eğitiyor.

Off-policy eğitim (Bölüm 5)

- SAC üzerine kurulu. Encoder, actor $\pi(a | s, z)$ ve critic $Q(s, a, z)$ birlikte eğitiliyor; z 'den gradyan reparametrizasyonla geçiyor.
- Encoder'ın gradyanı critic kaybı ile KL teriminden geliyor. Critic kaybı (Denklem 3); V hedef ağ, $\bar{z}$ gradyan geçirmeyen z :

$$\mathcal{L}_{critic} = \mathbb{E}_{(s,a,r,s') \sim \mathcal{B}} [Q_\theta(s,a,z) - (r + \bar{V}(s', \bar{z}))]^2$$

- Veri ayrımı: encoder'ın bağlamı, S_c örnekleyicisiyle yalnız en son toplanan veriden alınıyor; bu veri her 1000 meta-eğitim adımında yenileniyor. Actor ve critic batch'leri ise tüm replay buffer'dan. Gerekçe: test anında bağlam on-policy olacak; bağlamı tümüyle off-policy almak dağılım uyumsuzluğu yaratıyor.

- **Test (Algoritma 2):** ilk episode'da z prior'dan örneklenir. Her episode sonunda bağlam büyür, z posterior'dan yeniden örneklenir ve episode boyunca sabit tutulur. Bu, posterior sampling ile zamansal olarak tutarlı keşif sağlıyor. Raporlanan performans, bağlama iki yörünge eklendikten sonraki getiri.
- **Not:** yazarlar recurrent DDPG'yi bu kurguda çalıştıramadığını yazıyor. Ni et al. (bölüm 7) doğru tasarım seçimleriyle recurrent off-policy RL'nin rekabetçi olduğunu gösteriyor.

Hiperparametreler (resmi koddan, makalede yok)

Parametre	Değer	Koddaki ad
Latent (z) boyutu	5	latent_size
Encoder	MLP, 3×200 gizli; çıkış $2 \times \text{latent}$ (μ ve σ)	MlpEncoder, hidden_sizes
Encoder girdisi	(s, a, r); s' yalnız ayar açıksa eklenir (varsayılan kapalı)	use_next_obs_in_context
Actor, Q ve V ağları	3×300	net_size
KL ağırlığı β	0.1	kl_lambda
Bağlam batch'i	64 geçiş (Half-Cheetah-Vel'de 100)	embedding_batch_size
Meta batch	16 görev	meta_batch
Öğrenme oranları	$3e-4$ (policy, Q, V, context)	policy_lr, qf_lr, context_lr
γ, τ	0.99, 0.005	discount, soft_target_tau
Ödül ölçeği	5	reward_scale
Episode uzunluğu	200	max_path_length

Ablation'lar (Bölüm 6.3)

- **Encoder mimarisi (Şekil 5, Half-Cheetah-Vel).** Permütasyon-değişmez encoder yerine RNN (100 adım geri yayılım, bağlam tam yörünge): benzer performans, daha yavaş optimizasyon. RL batch'i de yörünge olarak örneklenirse performans sert düşüyor; RL için ilişkisiz (decorrelated) geçişler şart.

- **Bağlam örnekleme (Şekil 6).** Bağlamı tüm buffer'dan almak performansı belirgin düşürüyor. RL batch'ini bağlam olarak da kullanmak bunu kısmen telafi ediyor. Önerilen: son toplanan veri, RL batch'inden ayrı.
- **Deterministik z (Şekil 7, seyrek ödüllü 2D navigasyon).** z nokta tahmine indirilince keşif zamansal tutarlılığını kaybediyor ve görev çözümü yapıyor.
- Latent boyutu için ablation yok.

Ortamlar ve sonuç

- 6 MuJoCo ortamı, horizon 200: Half-Cheetah-Fwd-Back (2 görev), Half-Cheetah-Vel (100 eğitim / 30 test), Humanoid-Dir-2D (100 / 30), Ant-Fwd-Back (2), Ant-Goal-2D (100 / 30), Walker-2D-Params (40 / 10).
- Walker-2D-Params dışındakilerde değişen şey ödül fonksiyonu. Walker-2D-Params'ta dinamik parametreleri rastgele; TEP'e kavramsal olarak en yakın ortam bu.
- Meta-eğitimde ProMP, MAML-TRPO ve RL²'ye göre 20-100 kat daha az örnek kullanıyor. 6 alanın 5'inde nihai performans %50-100 daha yüksek.

13. VariBAD (Zintgraf et al., ICLR 2020): Bayes-adaptif meta-RL

Görev (rehber). Oku: encoder-decoder yapısının anlatıldığı yöntem bölümü. Ara: appendix'teki hiperparametreler; latent boyutuyla ilgili bir ablation varsa o kısım.

Ara'nın cevabı. Latent (task embedding) boyutu hem gridworld'de hem MuJoCo'da 5 (Ek B.2 ve C.6). Latent boyutu için ablation yok; makalede tek değer kullanılmış.

Encoder-decoder yapısı (Bölüm 3, Şekil 2)

- Her MDP öğrenilen, düşük boyutlu ve stokastik bir m ile temsil ediliyor. Ödül ve geçiş fonksiyonları görevler arasında paylaşıyor; göreve özgü olan tek şey m:

$$R_i(r_{t+1} \mid s_t, a_t, s_{t+1}) \approx R(r_{t+1} \mid s_t, a_t, s_{t+1}; m_i), \\ \text{\texttt{\textbackslash}qqquad} T_i(s_{t+1} \mid s_t, a_t) \approx T(s_{t+1} \mid s_t, a_t; m_i)$$

- **Encoder** $q_\phi(m \mid \tau_{1:t})$: o ana kadarki yörünge $\tau_{1:t} = (s_0, a_0, r_1, s_1, \dots, s_t)$ bir GRU ile çevrimiçi işleniyor. Her adımda posterior'un ortalaması ve varyansı çıkıyor.
- **Decoder** p_θ : m'den durumları ve ödülleri yeniden kuruyor. Yalnız eğitimde kullanılıyor, testte yok.
- **Politika** $\pi_\psi(a_t \mid s_t, q_\phi(m \mid \tau_{1:t}))$: posterior'un parametrelerine (μ ve σ) koşullanıyor, yani belirsizliği de görüyor. PEARL'deki gibi örneklenmiş tek bir z kullanmıyor.

- Encoder ve decoder çıkarılırsa yöntem RL²'ye indirgeniyor. Farklar: stokastik latent (belirsizlik için tümevarımsal önyargı) ve yardımcı kayıp gibi çalışan decoder.

Kayıp fonksiyonu (Denklem 8-10)

$$\mathrm{ELBO}_t = \mathbb{E}_{\rho}[\mathbb{E}_{q_{\phi}(m|\tau_{:t})}[\log p_{\theta}(\tau_{H^+}|m)]] - \mathbb{KL}[q_{\phi}(m|\tau_{:t}) \parallel p_{\theta}(m)]$$

$$\log p(\tau_{H^+}|m) = \log p(s_0|m) + \sum_{i=0}^{H^+-1} [\log p(s_{i+1}|s_i, a_i, m) + \log p(r_{i+1}|s_i, a_i, s_{i+1}, m)]$$

$$\mathcal{L}(\phi, \theta, \psi) = \mathbb{E}_{p(M)}[\mathcal{J}(\psi, \phi) + \lambda \sum_{t=0}^{H^+} \mathrm{ELBO}_t(\phi, \theta)]$$

- t anındaki geçmişten çıkan posterior ile yörüngenin tamamı (geçmiş ve gelecek) decode ediliyor. Klasik VAE'den farkı bu. Gelecek de decode edildiği için model, görülmemiş durumlar hakkında çıkarım yapmayı öğreniyor.
- KL'deki prior, bir önceki adımın posterior'u: $p(m) = q_{\phi}(m | \tau_{:t-1})$. Başlangıçta $N(0, I)$.
- ELBO her t için ayrı bir terim. Böylece model çevrimiçi çıkarım yapmayı ve veri geldikçe belirsizliği azaltmayı öğreniyor. H^+ büyükse rastgele t'ler alt-örneklenebiliyor.
- RL kaybı encoder'a geri yayılmıyor. Politika ve VAE ayrı optimizier, ayrı öğrenme oranı ve ayrı buffer'la eğitiliyor: politika yalnız son on-policy veriyle, VAE daha büyük bir yörünge buffer'ıyla. Yazarlara göre bu eğitimi hızlandırıyor ve karşıt kayıpların gradyan çakışmasını önüyor; Ni et al.'ın "ayrı encoder" bulgusuyla aynı yönde.
- MuJoCo'da yalnız ödül decoder'ı kullanılmış. Dinamiğin değiştiği Walker'da bile bu daha iyi sonuç vermiş.

BAMDP çerçevesi (Bölüm 2.2)

- Bayes-optimal politika duruma ve ortam hakkındaki belirsizliğe (belief) birlikte bakıyor; keşif yalnız getiriye artırdığı ölçüde yapılıyor. Hiper-durum $s^* = (s, b)$.
- BAMDP'de gizli olan şey (görev) episode boyunca sabit; genel POMDP'de gizli durum zamanla değişebilir. VariBAD bu sabitliği kullanıyor. TEP'te arıza episode ortasında başladığı için bu varsayım tam tutmuyor.
- $H^+ = N \times H$ seçilerek politika ilk N episode içinde Bayes-optimal davranmak üzere eğitilebiliyor. MuJoCo'da $H = 200$, $H^+ = 400$ (2 rollout); episode sınırı duruma "done" bayrağı olarak eklenmiş.

Hiperparametreler (Ek B.2 ve C.6)

Parametre	Gridworld	MuJoCo
RL algoritması	A2C	PPO
Task embedding (latent) boyutu	5	5
Encoder	FC 40 $\rightarrow$ GRU 64 $\rightarrow$ 10 çıkış (μ ve σ)	Durum, aksiyon ve ödül için FC 32 / 16 / 16 $\rightarrow$ GRU 128 $\rightarrow$ 5 çıkış (doğrula)
Politika	2×32 , tanh	2×128 , tanh
Ödül decoder'ı	2×32 , 25 çıkış başlığı; binary cross entropy	64 ve 32 gizli; MSE
ELBO ve KL ağırlığı	ELBO katsayısı 1.0	ELBO içindeki KL ağırlığı 0.1
Policy LR / VAE LR	0.001 / 0.001	0.0007 / 0.001
γ	0.95	yazmıyor
Diğer	16 paralel süreç, 60 policy adımı, entropi 0.01, GAE τ 0.95	Batch 3200, 2 epoch, 4 minibatch, clip 0.1, entropi 0.01, Huber kaybı

MuJoCo encoder'ının "5 çıkış" ifadesi gridworld'deki "10 çıkış (μ ve σ)" ile çelişiyor; μ ve σ 'nın ayrı başlıklar olup olmadığı kodda kontrol edilmeli.

Bulgular

- **Gridworld** (5×5 , $H = 15$, 4 episode üzerinden eğitim): VariBAD, Bayes-optimal davranışa çok yakın. 20 seed'in 4'ünde tam Bayes-optimal çözümü bulmuş, RL^2 hiç bulamamış.
- 4 episode üzerinden eğitilip 6 episode değerlendirildiğinde RL^2 'nin performansı 4. episode'dan sonra düşüyor (128 boyutlu gizli durumdaki kararsızlık). VariBAD'in 5 boyutlu posterior'u yoğunlaşıp sabit kalıyor.
- **Latent görselleştirme:** gridworld'de hedef bulununca varyans sıfıra yakın düşüyor, ortalama sabitleniyor. HalfCheetahDir'de ortalama ve log-varyans birkaç adımda uyum sağlıyor; iki görevde latent boyutlar işaret değiştiriyor.
- **MuJoCo** (AntDir, HalfCheetahDir, HalfCheetahVel, Walker): ilk rollout içinde uyum sağlayan yalnız VariBAD ve RL^2 . PEARL posterior sampling'e benzediği için ancak 3. episode'dan sonra iyi; buna karşılık meta-eğitimde çok daha örnek-verimli (off-policy).

- **Çalışma süresi** (HalfCheetahDir, kaba tahmin): ProMP ve E-MAML 5–8 saat, PEARL 24 saat, VariBAD 48 saat, RL² 60 saat.
- Yazarların önerisi (Ek C.5): latent'in neyi temsil ettiğini görmek için gerçek görev tanımını tahmin eden ayrı bir model eğitmek. Bu, probe yöntemiyle (Alain & Bengio) aynı fikir.

14. CaDM (Lee et al., ICML 2020): context-aware dynamics model

Görev (rehber). Oku: context encoder bölümü ve ileri/geri tahmin kayıpları; encoder'ın nasıl eğitileceğinin cevabı burada. Ara: farklı ortamlara genelleme deneyleri. Bölümün teması gereği latent boyutu da not edildi.

Encoder yalnızca dinamik tahmin kaybıyla eğitiliyor. Son K geçişten 10 boyutlu bir z çıkarılıyor, aynı z sonraki M adımın hem ileri hem geri tahmininde kullanılıyor.

Kurgu

- Geçiş dinamiği $p_c(s' | s, a)$, bilinmeyen bir bağlam c' 'ye bağlı. Eğitim bağlamları p_{train} 'den, test bağlamları görülmemiş p_{test} 'ten geliyor.
- Fikir: bağlam kodlamasını (encoder) geçiş tahmininden (dinamik model) ayırmak. GrBAL ve ReBAL gibi meta-RL yöntemleri adaptasyonu ve tahmini aynı modele yüklüyor; yazarlar bunun bağlamı iyi yakalamadığını savunuyor.
- Varsayım: benzer bağlamlı MDP'ler benzer davranır; bu yüzden eğitim bağlamlarına yakın görülmemiş dinamiklere genelleme mümkün.

Context encoder

- $z_t = g(\tau^P_{t,K}; \phi)$; $\tau^P_{t,K}$, son K geçiş.
- Girdi ham durum değil, durum farkı: $\{(\Delta s_{t-K}, a_{t-K}), \dots, (\Delta s_{t-1}, a_{t-1})\}$, $\Delta s_t = s_{t+1} - s_t$. Bu basit değişiklik ek performans artışı sağlamış.
- Mimari: MLP, 3 gizli katman, çıkış 10 boyut. Gizli katman genişliği yazmıyor.
- Dinamik modele bağlama: durum, aksiyon ve z birleştirilip (concatenate) girdi yapılıyor. Herhangi bir dinamik model mimarisiyle çalışıyor.

Kayıp fonksiyonu (Denklem 1)

$$\mathcal{L}^{\text{pred}} = \mathbb{E}_{(\tau^F_{t,M}, \tau^P_{t,K}) \sim \mathcal{B}} \left[\mathcal{L}^{\text{pred}}_{\text{forward}} + \beta \mathcal{L}^{\text{pred}}_{\text{backward}} \right]$$

$$\mathcal{L}^{\text{pred}}_{\text{forward}} = -\frac{1}{M} \sum_{i=t}^{t+M-1} \log f(\text{big}(s_{i+1} \mid s_i, a_i, g(\tau^P_{t,K}; \phi); \theta) \text{big})$$

$$\mathcal{L}^{\text{pred}}_{\text{backward}} = -\frac{1}{M} \sum_{i=t}^{t+M-1} \log b(\text{big}(s_i \mid s_{i+1}, a_i, g(\tau^P_{t,K}; \phi); \psi) \text{big})$$

- f ileri model: sonraki durumu tahmin eder. b geri model: önceki durumu tahmin eder. İkisi de aynı z'yi kullanır.
- t anındaki geçmişten çıkan z, sonraki M adımın hepsine uygulanıyor. Bu, z'nin zaman içinde tutarlı (yavaş değişen bağlamı temsil eden) olmasını zorluyor.
- Geri tahminin gerekçesi: yalnız "görölmüş" ileri dinamiğe aşırı odaklanma riskini azaltmak.
- Model, sabit varyanslı Gaussian; log-olabilirliği maksimize etmek MSE'yi minimize etmeye denk.
- ϕ , θ ve ψ aynı kayıpla birlikte güncelleniyor (Algoritma 1). Encoder getiri veya ödülle eğitilmiyor; PEARL'den farkı bu.
- Eğitim döngüsü: her iterasyonda bağlam örneklenir, o anki z ile MPC kullanılarak veri toplanır, sonra üç ağ güncellenir.

Hiperparametreler (Ek A.2-A.4)

Parametre	Değer
Latent (z) boyutu	10
K, geçmiş geçiş sayısı	5 veya 10
M, gelecek adım sayısı	5 veya 10
β , geri kayıp ağırlığı	0.25, 0.5 veya 1.0
Encoder	MLP, 3 gizli katman
Dinamik model (Vanilla DM)	MLP, 4×200 , Swish
Optimizier	Adam, lr $1e-3$
Planlama	MPC; CEM 200 aday (CartPole ve Pendulum'da random shooting, 1000 aday); ufuk 30
Veri	İterasyon başına 10 yörünge, 5 epoch; 20 iterasyon
Model-free kullanım	PPO; politika $\pi(a; s, z)$; MLP 2×64 , tanh; 5M adım

Karşılaştırılan PEARL tarzı (PPO + PC) ve environment probing (PPO + EP) baseline'larının encoder'ı da 10 boyutlu (MLP 256-128-64).

Genelleme deneyleri (Ara)

- Ortamlar ve değiştirilen parametre: CartPole (itme kuvveti, çubuk uzunluğu), Pendulum (kütle, uzunluk), HalfCheetah (kütle, sönüm), Ant (iki bacak m, iki bacak 1/m kütle), CrippledHalfCheetah (devre dışı bir eklem), SlimHumanoid (kütle, sönüm).
- Parametreler her episode başında örnekleniyor. Test, eğitim aralığı dışında iki rejimde: moderate (eğitime yakın) ve extreme (uzak). Örnek HalfCheetah: eğitim {0.75–1.25}, moderate {0.4, 0.5, 1.5, 1.6}, extreme {0.2, 0.3, 1.7, 1.8}.
- Değerlendirme: eğitimde en yüksek ortalama getirili model; 5 koşunun ortalaması.

Test getirileri, moderate / extreme (Tablo 1):

Ortam	Vanilla DM	Vanilla + CaDM	PE-TS	PE-TS + CaDM	Stacked DM
CartPole	124.7 / 105.9	154.3 / 118.6	171.3 / 142.9	187.3 / 149.4	131.9 / 106.6
Pendulum	-928.4 / -1170.6	-593.7 / -967.9	-985.7 / -1221.1	-705.5 / -1098.4	-1308.0 / -1288.3
HalfCheetah	1026.7 / 686.7	1556.1 / 1264.5	2019.6 / 1422.3	7087.2 / 4661.8	761.1 / 661.5
Ant	520.0 / 385.8	1315.7 / 821.4	1075.1 / 856.6	2121.0 / 1200.7	417.1 / 338.9
CrippledHalfCheetah	870.0 / 577.3	1375.3 / 966.9	1916.5 / 1227.6	2618.7 / 1294.2	545.1 / 417.9
SlimHumanoid	1004.4 / 1155.5	1228.9 / 1487.9	758.6 / 810.4	903.7 / 814.5	876.2 / 651.8

- CaDM, iki temel modeli de tüm ortamlarda iyileştiriyor; kazanç karmaşık ortamlarda çok daha büyük.
- Stacked DM (geçmiş 10 geçişi doğrudan girdiye eklemek) çoğu ortamda Vanilla'dan bile kötü. Geçmiş ayrı bir encoder'la özetlemek, ham yığmaktan daha etkili.
- GrBAL ve ReBAL en zayıf ve en kararsız sonuçları veriyor.
- Tahmin hatası (Şekil 6b, 17): PE-TS eğitim aralığı dışında hızla bozuluyor, CaDM kabul edilebilir hatada kalıyor.
- Gömme analizi (Şekil 6c, 18–19): z vektörleri parametre değerine göre net kümeleniyor; ham durum-aksiyon vektörleri kümelenmiyor (Şekil 20–21). Latent'in bağlamı taşıdığını gösteren, probe testine benzer bir kontrol.
- Eğitim aralığı genişledikçe CaDM'in genellemesi artıyor, Vanilla'nınki artmıyor (Ek B).
- Kayıp ablation'ı (Şekil 6a, 15–16): tek adım ileri < çok adım ileri < çok adım ileri + geri (HalfCheetah, extreme). Ant'ta çok adımlı tahmin büyük kazanç sağlıyor; CartPole ve Pendulum'da fark küçük.

- Model-free (Tablo 2): PPO + CaDM, karmaşık ortamlarda PPO + PC ve PPO + EP'den iyi genelliyor. Örnek, HalfCheetah moderate: 1224.2, Vanilla PPO 807.7. Basit ortamlarda kazanç marjinal.

15. RMA (Kumar et al., RSS 2021): iki aşamalı eğitim

Görev (rehber). Oku: mimari bölümü; ortam parametrelerinin küçük bir latent vektöre (extrinsics) sıkıştırılması ve bu vektörün geçmiş gözlemlerden tahmin edildiği iki aşamalı eğitim. Ara: latent boyutu ve adaptation modülünün baktığı geçmiş uzunluğu.

Ara'nın cevabı. Extrinsics z_t 8 boyutlu ve 17 boyutlu ortam vektörü e_t 'den sıkıştırılıyor. Adaptation modülü son $k = 50$ adıma bakıyor; 100 Hz kontrol frekansında bu 0.5 saniye. İki değer için de ablation yok.

İki aşamalı eğitim (Bölüm III, Algoritma 1)

1. **Aşama 1, RL.** Base policy π ve environment factor encoder μ birlikte PPO ile eğitilir. μ , simülatörden gelen ayrıcalıklı (privileged) e_t 'yi z_t 'ye sıkıştırır.
2. **Aşama 2, gözetimli öğrenme.** π ve μ dondurulur. Adaptation modülü ϕ , son k durum-aksiyon çiftinden $\hat{z}_t$ 'yi tahmin eder; hedef, μ 'nün ürettiği z_t .

$$z_t = \mu(e_t), \quad a_t = \pi(x_t, a_{t-1}, z_t), \quad \hat{z}_t = \phi(x_{t-k:t-1}, a_{t-k:t-1}), \quad \mathcal{L}_\phi = \|\hat{z}_t - z_t\|^2$$

- Aşama 2 verisi on-policy toplanıyor (DAgger benzeri). π , ϕ 'nin (başta rastgele) tahmini $\hat{z}_t$ ile çalıştırılıyor; durum-aksiyon geçmişi gerçek z_t ile eşleniyor. Bu, yakınsayana kadar tekrarlanıyor.
- Gerekçe: yalnız gerçek z_t ile toplanan yörüngeler "iyi" durumlardır. Bunlarla eğitilen ϕ , uygulamada sık sık yaşanan sapmalara dayanıksız kalıyor. UP-OSI'deki "kötü durumları ekleme" fikriyle aynı.
- ϕ , e_t 'yi değil z_t 'yi tahmin ediyor; z_t yalnız davranışın nasıl değişmesi gerektiğini kodluyor. Yazarların gerekçeleri: aynı etkiye sahip parametreler birlikte değişebilir (tanımlanabilirlik sorunu); önemli olan z 'nin "doğru" olması değil, doğru aksiyonu üretmesi.
- Alternatif olarak geçmiş doğru base policy'ye veren uçtan uca bir politika denenmiş. Sonuç: doğal olmayan yürüyüş ve düşük performans; robot üzerinde yalnız 10 Hz çalışabiliyor.

Mimari ve boyutlar (Bölüm IV-B)

Bileşen	Girdi → çıktı	Yapı
Environment factor encoder μ	$e_t \in \mathbb{R}^{17} \rightarrow z_t \in \mathbb{R}^8$	MLP, 3 katman (256 ve 128 gizli)
Base policy π	$x_t \in \mathbb{R}^{30}, a_{\{t-1\}} \in \mathbb{R}^{12}, z_t \in \mathbb{R}^8 \rightarrow a_t \in \mathbb{R}^{12}$ (hedef eklem açıları)	MLP, 3 katman, 128 gizli
Adaptation modülü ϕ	Son 50 adımın (x, a) çiftleri $\rightarrow \hat{z}_t \in \mathbb{R}^8$	2 katmanlı MLP ile 32 boyuta gömme; zaman ekseninde 3 katmanlı 1-D CNN; düzleştirilip doğrusal projeksiyon

- CNN katmanları [giriş kanalı, çıkış kanalı, kernel, stride]: [32, 32, 8, 4], [32, 32, 5, 1], [32, 32, 5, 1].
- e_t 'nin 17 boyutu: yük kütlesi ve konumu (3), motor gücü (12), sürtünme (1), yerel zemin yüksekliği (1).
- Durum x_t 'nin 30 boyutu: eklem konumları (12), eklem hızları (12), gövde roll ve pitch (2), ayak temas göstergeleri (4).
- Not: 50 adımlık pencereye bakan küçük bir CNN tercih edilmiş, RNN değil.

Eğitim ayrıntıları

- **Aşama 1:** PPO, 15,000 iterasyon; iterasyon başına 80,000 geçiş (4 mini-batch), $\text{lr } 5e-4$, GAE $\lambda 0.95$, $\gamma 0.998$. Yaklaşık 24 saat ve 1.2 milyar simülasyon adımı.
- **Aşama 2:** Adam ile MSE, 1000 iterasyon, batch 80,000, $\text{lr } 5e-4$. Yaklaşık 3 saat ve 80 milyon adım.
- Ödül cezaları küçük bir çarpanla ($k_0 = 0.03$) başlıyor ve sabit bir müfredatla artırılıyor ($k_{\{t+1\}} = k_t^{0.997}$). Aksi halde ajan yerinde kalıyor ya da düşüyor.
- Ortam parametreleri episode içinde de değişiyor: adım başına yeniden örnekleme olasılığı eğitimde 0.004, testte 0.01.

Eğitim ve test aralıkları (Tablo I); test aralığı bilinçli olarak daha geniş:

Parametre	Eğitim	Test
Sürtünme	0.05–4.5	0.04–6.0
Kp	50–60	45–65
Kd	0.4–0.8	0.3–0.9

Parametre	Eğitim	Test
Yük (kg)	0-6	0-7
Kütle merkezi (cm, metinde böyle)	-0.15-0.15	-0.18-0.18
Motor gücü	0.90-1.10	0.88-1.22
Adım başına yeniden örnekleme olasılığı	0.004	0.01

Asenkron çalışma

- ϕ 10 Hz'de, π 100 Hz'de çalışıyor; π her adımda ϕ 'nin en son tahminini kullanıyor. Bu, extrinsics'in robot durumundan çok daha yavaş değişmesine dayanıyor.

Sonuçlar (Tablo II, simülasyon)

Parametreler episode içinde değişiyor; 3 politika $\times$ 1000 episode ortalaması.

Yöntem	Başarı (%)	TTF	Ödül	Mesafe (m)
Expert (gerçek z_t ile, üst sınır)	76.2	0.86	5.23	1.35
RMA	73.5	0.85	5.22	1.34
Robust (domain randomization)	62.4	0.80	4.62	1.13
SysID (e_t 'yi doğrudan tahmin)	56.5	0.74	4.82	1.17
RMA, adaptation modülü yok	52.1	0.75	4.72	1.15
AWR (z 'yi gerçek rollout'larla optimize, 40k örnek)	41.7	0.65	4.17	0.95

- SysID'nin düşük performansına yazarların yorumu: e_t 'yi açıkça tahmin etmek hem zor hem gereksiz.
- Gerçek robotta adaptasyon 1 saniyenin altında. Yağlı yüzeyde (Şekil 4) ve 5 kg yük atıldığında (Şekil S3), $\hat{z}$ 'nin bazı bileşenleri olay anında belirgin sıçırıyor. Olay sürdükçe yeni değerde kalıyor; robotun yürüyüşü toparlansa bile.
- Bu davranış, TEP'te arıza başlangıcının latent'te nasıl görünmesi gerektiğine dair iyi bir referans.

16. UP-OSI (Yu et al., RSS 2017): açık sistem tanımlama

Görev (rehber). Oku: giriş bölümü ve OSI modülünün tanımı. Latent yaklaşımına alternatif olarak kavramsal düzeyde bilmek yeterli.

UP-OSI latent kullanmıyor. Politika doğrudan fiziksel parametre vektörü μ 'ye koşullanıyor; OSI bu μ 'yü son birkaç adımdan tahmin ediyor. RMA'nın SysID baseline'ı bu yöntem.

İki bileşen (Bölüm III)

- **Universal Policy (UP):** $\pi(x, \mu) \rightarrow u$. Parametrik dinamik ailesi $x_{t+1} = f_{\mu}(x_t, u_t)$ üzerinde TRPO ile eğitiliyor. Her rollout için μ uniform dağılımdan örnekleniyor ve gerçek değeri girdi olarak veriliyor. μ simülasyonla değişmediği için TRPO'nun keşif şeması buna göre uyarlanmış.
- **Online System Identification (OSI):** $\phi(x_{t-h:t}, u_{t-h:t-1}) \rightarrow \mu$. Güncel durum ve son h adımın durum-aksiyon çiftlerinden parametreyi tahmin eden bir regresyon ağı (Denklem 1):

$$\theta^* = \arg\min_{\theta} \sum_{(H_i, \mu_i) \in \mathcal{B}} \|\phi_{\theta}(H_i) - \mu_i\|^2$$

- Çalışma anında her adımda OSI $\hat{\mu}$ 'yi tahmin ediyor, UP $(x_t, \hat{\mu})$ ile aksiyonu üretiyor ve (x_t, u_t) geçmiş kuyruğuna ekleniyor.
- Geleneksel sistem tanımlamadan farkı: belirli bir sistemi tanımlamak değil, herhangi bir yörünge için parametreyi veren bir fonksiyon öğrenmek. Gerçek dünya verisi gerekmiyor.
- Parametreler zamanla değişebiliyor: sürtünme veya taşınan nesnenin kütlesi gibi önceden tanımlanamayan büyüklükler çevrimiçi izlenebiliyor.

OSI'nin iteratif eğitimi (Algoritma 2)

1. İlk tur: UP gerçek μ ile çalıştırılıyor; kısa geçmiş segmentleri (H, μ) çiftleri olarak buffer'a ekleniyor. Bununla eğitilen OSI kapalı çevrimde kötü çalışıyor, çünkü yalnız "iyi" durumları görmüş. Küçük bir tahmin hatası, sonraki adımları da bozuyor.
2. Sonraki turlar: UP, OSI'nin tahmini $\hat{\mu}$ ile çalıştırılıyor, simülasyon ise gerçek μ ile yapılıyor. Bu uyumsuz örnekler buffer'a ekleniyor ve OSI yeniden eğitiliyor.
3. 3–5 tur sonra UP-OSI, gerçek μ verilen UP'ye (UP-true) yaklaşıyor. RMA'nın aşama 2'deki on-policy veri toplama fikri bunun devamı.

Ayarlar (Bölüm IV)

- UP: 2×64 tanh gizli katman, doğrusal çıkış; 500 TRPO iterasyonu.

- OSI: 256, 128 ve 64 birimlik üç tanh katmanı, her katmandan sonra dropout 0.1. 5 iterasyon; iterasyon başına 30 farklı μ değeri ve her biri için 5 saniyelik veri.
- **Geçmiş uzunluğu $h = 3$.** Gerekçe: ikinci dereceden bir dinamik modeli öğrenmek için gereken en kısa uzunluk. Simülasyon adımı 0.002 s (DART).
- Testler: çift ters sarkaç (kütle merkezi ofseti, $\mu \in [-0.6, 0.6]$ m), robot kolunun blok fırlatması (blok kütlesi), Hopper (sürtünme, $\mu \in [0.3, 1.0]$), cart-pole swing-up (çubuk uzunluğu 0.2–0.8 m, uç kütlesi 0.1–1.0 kg ve sistem hızı; $\mu \in \mathbb{R}^4$).

Bulgular

- UP-OSI, gerçek μ verilen UP'ye yakın performans veriyor. OSI tahminleri gerçek değerleri izliyor (Şekil 2d, 3c, 4c).
- Episode içinde değişen sürtünme (Hopper, 20–30 m arası farklı μ): OSI değişimi izliyor, oysa eğitimde zamanla değişen μ hiç gösterilmemiş. Değişimden habersiz, sabit $\mu = 0.9$ verilen UP belirgin daha kötü.
- Eğitim aralığının %100 dışında (cart-pole, uzunluk 0.8–1.4 m ve kütle 1.0–1.9 kg) UP-OSI, UP-true'yu geçiyor. Yazarların açıklaması: OSI parametreyi zamanla modüle ederek mevcut politikalar arasında geçiş yapıyor.
- Sınırlar: yüksek boyutlu μ 'nün tanımlanması çözülmemiş (en fazla $\mathbb{R}^4$ denenmiş). Ölçüm ve aktuatör gecikmesi geçmiş kuyruğu şemasını karmaşıktırabilir. Recurrent uçtan uca politika alternatif olarak anılıyor.

17. Alain & Bengio (2016): linear classifier probe

Görev (rehber). Oku: yalnızca probe yönteminin tanımı. Latent vektör bu yöntemle test edilecek.

Probe, bir ağın ara katmanındaki özniteliklerden hedef değişkeni tahmin eden doğrusal bir sınıflandırıcı. Ağdan bağımsız eğitiliyor ve ağı değiştirmiyor. Ölçtüğü soru: "bu temsilde X bilgisi doğrusal olarak okunabiliyor mu?"

Tanım (Bölüm 3.2)

$$f_k : H_k \rightarrow [0,1]^D, \quad f_k(h_k) = \mathrm{softmax}(W h_k + b)$$

- h_k , k . katmanın öznitelikleri; (W, b) probe parametreleri; eğitim olağan çapraz entropi kaybıyla. Ölçülen büyüklük probe'un eğitim, doğrulama ve test kaybı (L_k^{train} , L_k^{valid} , L_k^{test}) ya da sınıflandırma hatası.
- Probe modeli etkilemiyor: probe'dan modele gradyan akışı kesiliyor (stop_gradient) ya da probe parametreleri model parametrelerinden ayrı yönetiliyor.

- Softmax ve çapraz entropiyle doğrusal sınıflandırıcı eğtmek konveks bir problem; yerel minimum yok. Bu yüzden ölçüm, probe'un nasıl optimize edildiğinden bağımsız sayılabiliyor.
- Yazarların benzetmesi: probe'lar, modelin farklı noktalarına aynı anda konan termometreler.
- Probe herhangi bir hedefe uygulanabiliyor (Bölüm 3.6). Aslında sorulan şey: "modelin bu kısmında şu faktöre dair bilgi var mı?"

Bilgi ve doğrusal ayrılabilirlik (Bölüm 3.1)

- Veri işleme eşitsizliği: $X \rightarrow Y \rightarrow Z$ ise $I(X; Z) \leq I(X; Y)$. İleri yayılımı yeni bilgi eklenmiyor; her katman bir öncekinden fazla bilgi taşıyamıyor.
- Yine de derin katmanlar doğrusal sınıflandırıcıya daha uygun. Ağ bilgiyi artırmıyor, hesaplamaya elverişli bir temsile damıtıyor. Probe'un ölçtüğü şey bilgi miktarı değil, bilginin doğrusal erişilebilirliği.
- Deneylerde probe hatası derinlikle neredeyse monoton azalıyor; eğitim amacı bunu doğrudan istemediği halde.

Pratik notlar (Bölüm 3.3–3.5, 5.1, 6)

- Doğrulama kaybı ($L_{k^{valid}}$) izlemek daha anlamlı; makalede çoğunlukla sınıflandırma hatası raporlanmış.
- Öznitelik sayısı çok büyükse probe aşırı uyum yapabiliyor ve ölçüm anlamını yitiriyor. Öneriler: sabit, rastgele bir öznitelik alt kümesi kullanmak ya da (görüntülerde) uzamsal havuzlama. Öğrenilen bir izdüşüm önerilmiyor.
- Eğitilmemiş, rastgele ağırlıklı bir modelin ilk katmanları bile probe'da iyi sonuç verebiliyor; rastgele izdüşümler sınıflandırmada işe yarayabiliyor (Bölüm 3.5). Çıkarım: probe sonucu, rastgele başlatılmış aynı modelle karşılaştırılmadan yorumlanmamalı.
- Teşhis kullanımı (Bölüm 5.1): 128 katmanlı bir ağda uzun bir skip connection'ın ağın ilk yarısını kullanılmaz bıraktığını probe'lar gösterdi; eğitim kaybı bunu göstermiyordu.
- Çok katmanlı probe fikri tartışılıyor; konveksliği kaybettiği için yazarlar bunu şimdilik erken buluyor.

18. Projeye çıkarımlar

Bu on yedi kaynak 3 dakikalık timestep, 60–64 adımlık bağlam ve 5–10 boyutlu bir latent ile başlamayı destekliyor. Severity için Bathelt modeli (temexd_mod ve yapı bayrağının 7. biti) gerekiyor.

Latent yaklaşımlarının karşılaştırması

Makale	Latent boyutu	Encoder girdisi	Geçmiş uzunluğu	Encoder mimarisi	Encoder'ı eğiten sinyal
PEARL	5 (koddan)	(s, a, r) geçişleri	Sırasız küme; bağlam batch'i 64-100 geçiş	MLP 3 × 200, Gaussian faktörlerin çarpımı	Critic'in Bellman kaybı + KL ($\beta = 0.1$)
VariBAD	5	(s, a, r) yörüngesi	Episode başından itibaren tüm geçmiş ($H^* = 400$)	FC gömme + GRU 128	ELBO: ödül (ve durum) yeniden kurma + KL; RL gradyanı yok
CaDM	10	(Δs , a)	K = 5-10 geçiş	MLP, 3 gizli katman	İleri + geri dinamik tahmini, M = 5-10 adım
RMA	8	(x, a)	k = 50 adım (0.5 s)	MLP gömme + 1-D CNN	Aşama 1: RL ile $\mu(e_t)$; aşama 2: MSE ile $\hat{z} \rightarrow z$
UP-OSI	Latent yok; μ doğrudan (1-4 boyut)	(x, u)	h = 3 adım	MLP 256-128-64	Fiziksel parametre regresyonu (MSE)

Beş makalenin hiçbirinde latent boyutu veya geçmiş uzunluğu için ablation yok; değerler tek seçim olarak verilmiş.

Proje kararları

- 1. Timestep.** Simülatörün iç adımı yaklaşık 1 s (en hızlı mod 1.8 s), ama bütün açık veri setleri (Braatz, Rieth, Reinartz) 3 dakikayla örnekliyor. 3 dakikada analizör kanalları basamaklı görünür: XMEAS 23-36 iki adımda bir, 37-41 beş adımda bir değişir; ürün bilgisi 15-30 dakika eskidir. 6 dakikanın altındaki her timestep'te analizör kanalları tekrar eden değerlerden oluşur. Kendi simülasyonunda Δt 'yi değiştireceksen Bathelt modelini kullan; bayrağın 5. ve 6. bitleri rastgele bozucuların çözücüyü ve adıma bağımlılığını gideriyor. Entegrasyon adımı (en fazla 0.1 saat, Euler'de 1 s) RL adımından ayrı tutulmalı. RL adımı değişirse Tallec'e göre γ fiziksel ufku koruyacak şekilde yeniden ölçeklenmeli ($\gamma_{\text{yeni}} = \gamma_{\text{eski}}^{(\Delta t_{\text{yeni}}/\Delta t_{\text{eski}})}$) ve ödül Δt ile çarpılmalı. Örnek: 3 dakikada $\gamma = 0.99$ yaklaşık 100 adım, yani 5 saatlik bir ufuk demek; 1 dakikaya inilirse aynı ufuk için $\gamma \approx 0.9967$ olmalı. Adım küçüldükçe TD3 ve SAC gibi Q tabanlı yöntemlerde aksiyonların Q üzerindeki farkı küçülüyor; 3 dakikanın altına inilecekse DAU tarzı $V + \delta t \cdot A$ ayrımı değerlendirilmeli.
- 2. Pencere uzunluğu.** Lomov'da zor arızaların (13, 17, 18, 20, 15) ortalama algılama gecikmesi 28-56 adım. Ni'nin en iyi varyantlarının çoğu 64 adım kullanıyor. 3 dakikada 60-64 adım yaklaşık 3-3.2 saat; iki makale aynı bölgeyi gösteriyor. Ni'ye göre optimum göreve özgü, bu yüzden 5 / 64 / uzun karşılaştırması yapılmalı. Zeng'e göre uzun

pencereden her model faydalanmıyor: doğrusal model yaklaşık 336 adıma kadar iyileşirken Transformer'lar bozuluyor. Mamba'nın gerekçesi de aynı: alakasız geçmiş atamayan modeller uzun bağlamdan yararlanamıyor. TEP'te 336 adım 16.8 saat eder; uzun pencere denenecekse encoder bunu kaldırabilmeli. Basit bir doğrusal model, pencere seçimi için ucuz ve güçlü bir referans.

3. **Encoder girdisi ve geçmiş uzunluğu.** Latent makaleleri pencereyi sistemin dinamik zaman ölçeğine göre seçiyor: UP-OSI 3 adım (ikinci derece dinamik için en az), CaDM 5-10 geçiş, RMA 50 adım (0.5 s). TEP'te CaDM'in $K = 10$ 'u 30 dakika eder; bu, ürün analizörünün gecikmesiyle aynı mertebede ve yavaş arızalar için kısa. RMA'nın 50 adımı 3 dakikada 2.5 saat eder ve Lomov'daki zor arıza gecikmeleriyle örtüşüyor. CaDM'deki gibi ham durum yerine Δs kullanmak denenmeli. Encoder mimarisi için GRU'ya ek olarak S4 (LTI) ve Mamba (seçici) denenebilir. Mamba yazarları seçiciliğin pürüzsüz, düzenli örneklenmiş sinyallerde (ses) zarar verebildiğini gösteriyor. TEP ölçümleri bu türden; ama arıza başlangıcı gibi ani olaylar seçiciliğin işe yarayabileceği yerler.
4. **Encoder'ı eğiten sinyal.** Beş seçenek var: dinamik tahmini (CaDM), critic kaybı (PEARL), VAE yeniden kurma (VariBAD), ayrıcalıklı bilgidan damıtma (RMA), açık parametre regresyonu (UP-OSI). CaDM kaybı (ileri + β ·geri, M adım) doğrudan uyarlanabilir. TEP simülatöründe gerçek IDV ve genlik bilgisi var, bu yüzden RMA tarzı iki aşamalı eğitim de uygulanabilir. Gerçek tesiste bu bilgi olmayacağı için CaDM veya VariBAD tarzı öz-denetimli kayıp daha taşınabilir. RMA'da SysID'nin zayıf kalması, arıza parametrelerini açıkça tahmin etmek yerine davranışa yönelik bir latent tahmin etmenin daha iyi olabileceğini gösteriyor.
5. **Latent boyutu.** Referanslar 5 (PEARL, VariBAD), 8 (RMA) ve 10 (CaDM); hiçbirinde ablation yok. RMA, 17 boyutlu bir parametre vektörünü 8'e sıkıştırıyor. TEP'te gizli faktörler 28 IDV, bunların genlikleri ve çalışma modu. Bu yüzden 8 ile başlayıp 4 / 8 / 16 ablation'ı yapılması önerilir; probe testi hangi boyutun arıza bilgisini taşıdığını gösterir.
6. **Actor-critic ve gradyan akışı.** Ni'ye göre actor ve critic için ayrı RNN encoder kullanılmalı. VariBAD da RL kaybını encoder'a geri yaymıyor ve ayrı optimizer kullanıyor. Ortak nokta: farklı kayıpların gradyanlarının aynı encoder'da çakışmasını önlemek. Önceki ödül girdiye eklemek gizli bilgiyi açığa çıkarabilir; TEP'te ödül maliyete dayalı olacağı için bu kanal anlamlı.
7. **Geçişlerin sırası.** PEARL'in encoder'ı geçişlerin sırasını yok sayıyor ve görevin episode boyunca sabit olduğunu varsayıyor. TEP'te arıza episode ortasında başlıyor ve analizör gecikmeleri gözlemi kısmi yapıyor. Bu yüzden sırayı koruyan bir encoder (VariBAD'deki GRU ya da RMA'daki 1-D CNN) daha uygun. RMA ve UP-OSI, episode içinde değişen parametreyi izleyebildiklerini gösteriyor. Zeng'in karıştırma deneyi de sırayı kullanmayan modellerin zaman serisinde bilgi kaybettiğini gösteriyor.

8. **Stokastik latent.** PEARL'de deterministik z, seyrek ödüllü görevde keşfi öldürüyor; VariBAD politikaya posterior'un μ ve σ 'sını veriyor. TEP'te ödül yoğun olduğu için posterior sampling'le keşif daha az kritik. Ama arıza başlangıcındaki belirsizliği (σ) politikaya vermek yararlı olabilir.
9. **On-policy encoder verisi.** RMA ve UP-OSI'nin ikisi de, encoder'ı yalnız gerçek parametreyle toplanan "iyi" yörüngelerle eğitmenin kapalı çevrimde başarısız olduğunu gösteriyor. PEARL de bağlamı son on-policy veriden alıyor. TEP'te encoder, politikanın kendi hatalı tahminleriyle oluşan yörüngelerle de eğitilmeli.
10. **PI baseline.** Ricker Tablo 2 temel alınır. Setpoint'ler kaynaklar arasında farklı: Ricker makalesi 2850 kPa ve reaktör seviyesi %55 öneriyor, Bathelt-Reinartz Multiloop modeli 2800 kPa ve %65 kullanıyor. Reinartz verisiyle karşılaştırılabilirlik için Bathelt kodundaki değerler daha tutarlı. Tablo 2'de okunamayan değerler (döngü 10, 18, 19) kodlamadan önce doğrulanmalı.
11. **Severity ve test aralığı.** Downs & Vogel'da IDV yalnızca 0/1 bayrağı, genlik parametresi yok; README'deki sorunun kökü bu. Bathelt revizyonunda aktivasyon değeri 0-1 arasında verilince bozucu genliği %0-100 ölçekleniyor (yapı bayrağının 7. biti); Reinartz'ın 227 bayrağı bunu içeriyor ve %25 / 50 / 75 / 100 genlikler böyle üretilmiş. %100'ün üstüne çıkılamıyor. Arızayı episode ortasında başlatmak ve genliği değiştirmek için bozucu vektörünü giriş olarak alan temexd_mod kullanılmalı. RMA, UP-OSI ve CaDM test aralığını bilinçli olarak eğitim aralığının dışına taşıyor. TEP'te de benzer bir kurgu kurulabilir: örneğin %25-75 genlikle eğitip %100 genlikte test etmek.
12. **Domain randomization.** Tobin'e göre çeşitlilik yeterince büyükse model, test koşulunu eğitimdeki varyasyonlardan biri gibi görür; ablation'da belirleyici faktör çeşitlik miktarı. TEP'te IDV, genlik, çalışma modu, setpoint ve seed randomize edilmeli; Bathelt modelindeki seed parametresi ve temexd_mod bunu mümkün kılıyor. Aynı kurgu iki baseline'ı da besliyor: latent'siz dayanıklı politika (RMA'daki Robust) ve latent'li yöntemler.
13. **Etiketleme ve durağanlık.** TEP'te arıza episode ortasında başlıyor (veri setine göre 1., 8. veya 30. saatte). Ni'nin sınıflamasında ve VariBAD'ın BAMDP çerçevesinde gizli durum episode içinde sabit kabul ediliyor; TEP'te ise başlangıç anında bir kez değişiyor. Başlangıcı içeren pencereler öncesi ve sonrasını karıştırır. Lomov'daki önek etiketleme sorunu bunun bir örneği; pencereler arıza başlangıcına göre etiketlenmeli. RMA'da $\hat{z}$ 'nin olay anında sıçrayıp yeni değerde kalması, TEP'te beklenecek latent davranışı için iyi bir model.
14. **Terminal durumlar ve probe hedefleri.** Downs & Vogel shutdown limitleri RL'de terminal durumlardır; Reinartz'ın "Simulation stopped" koşulları bunların hazır örnekleri. Reinartz'ın idv_monitoring verisindeki gürültüsüz bozucu değerleri, latent vektör için probe testinde (Alain & Bengio) hedef değişken olarak kullanılabilir. VariBAD'ın yazarları da (Ek C.5) latent'i gerçek görev tanımını tahmin eden ayrı bir modelle

incelemeyi öneriyor. Alain & Bengio'ya göre probe doğrusal olmalı, encoder'dan gradyan almamalı ve doğrulama verisinde (ayrı seed'ler) ölçülmeli. Hedefler: IDV sınıfı (softmax probe), genlik ve idv_monitoring değerleri (doğrusal regresyon). Karşılaştırma için aynı probe ham gözlem penceresine ve rastgele başlatılmış bir encoder'a da uygulanmalı; eğitilmemiş ağırlar da anlamlı probe sonucu verebiliyor.

19. Durum ve sıradaki adım

Rehberdeki 18 kaynağın 17'si okundu ve okuma sırasının dört adımı da tamamlandı. Chiang, Russell, Braatz (kitap) kapsam dışı bırakıldı; rehberin ondan istediği bilgilerin özeti Reinartz ve Rieth bölümlerinde var.

- Okuma sırası: adım 1 Ni et al. ve CaDM; adım 2 Downs & Vogel ve Ricker; adım 3 Lomov et al.; adım 4 PEARL, VariBAD ve RMA. Hepsi tamam.
- İhtiyaç oldukça grubundan okunanlar: Rieth (ikincil kaynaklardan), Reinartz, Bathelt, Tobin, Tallec, Mamba, Zeng, UP-OSI, Alain & Bengio.
- Kapsam dışı: Chiang, Russell, Braatz (kitap). Reinartz bölümündeki ön bilgi: Braatz verisi Mod 1, 21 arıza, eğitim 500 / test 960 gözlem, 3 dakika örnekleme. İki kez gönderilen rieth.pdf dosyası aslında Reinartz et al. (2021); Rieth bölümü bu yüzden ikincil kaynaklardan derlendi.

Sıradaki iş önerisi:

1. Bathelt kodunu (temexd_mod, bayrak 227) kurup Ricker PI baseline'ını çalıştırmak; aşağıdaki Ricker doğrulamalarını bu sırada kapatmak.
2. Ortamı domain randomization ile kurmak: IDV, genlik (örneğin eğitimde %25-75, testte %100), çalışma modu ve seed.
3. Encoder ablation planı: pencere 5 / 64 / 336, latent 4 / 8 / 16, encoder GRU / S4 / Mamba; her varyantı probe testiyle değerlendirmek.

Doğrulanacaklar:

- ☐ Ricker Tablo 2: döngü 10'un kazanç üssü; döngü 18 ve 19'un kazanç ve integral süreleri.
- ☐ Ricker Denklem 6: r3 denklemindeki işaret.
- ☐ Reinartz grup 2: 504 koşunun 5 geçiş profilini içerip içermediği.
- ☐ Lomov: normalizasyon istatistiklerinin yalnız eğitim verisinden mi hesaplandığı.
- ☐ PEARL: ICML 2019 sürümünde hiperparametre tablosu olup olmadığı (gönderilen arXiv v1'de yok; değerler resmi koddan).
- ☐ VariBAD: MuJoCo encoder'ının çıkış sayısı (5 mi, μ ve σ için 10 mu); resmi kodda kontrol.
- ☐ Bathelt Tablo 4: aktivasyon dizisi "20 bozucu" olarak tanımlanmış; IDV 21-28'in nasıl etkinleştirildiği ve ölçeklendiği kodda kontrol.

- ☐ Rieth: Harvard Dataverse açıklamasıyla karşılaştırma (bu ortamdan açılmadı); özellikle eğitimde arızanın 1. saatte başladığı ve orijinal dosya biçimi.